



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین شماره دو

دانشجویان:

سوال اول: علی رجب زاده ۸۱۰۱۰۴۱۳۷

سوال دوم: رضا مرید شوشتری ۸۱۰۱۰۴۲۵۰

فهرست مطالب

۳	فهرست تصاویر
۵	فهرست جداول
۶	۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی
۶	۱-۱ آماده‌سازی مجموعه داده
۷	۲-۱ پیش‌پردازش داده‌ها
۸	۳-۱ مدل AlexNet
۱۲	۴-۱ مدل پیشنهادی مقاله INC-VGGN
۱۲	۵-۱ پیاده‌سازی
۱۶	۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور
۱۶	۱-۲ آماده‌سازی مجموعه داده‌ها
۱۷	۲-۲ پیش‌پردازش داده‌ها
۱۸	۳-۲ پیاده‌سازی
۱۹	۴-۲ ارزیابی
۲۳	۵-۲ تحلیل و بهینه‌سازی
۲۳	۱-۵-۲ تاثیر داده افزایی
۲۵	۲-۵-۲ نقش بهینه ساز
۲۶	۳-۵-۲ بهینه سازی توسط fine-tuning

فهرست تصاویر

۱	نمودار هیستوگرام مربوط به تعداد داده‌های هر کلاس انتخابی از دیتاست rice-disease-
۶	dataset
۸	نمودار سه شکل انتخابی اولیه و نتیجه اعمال هر یک روش‌های داده‌افزایی انتخاب‌شده . . .
۸	نمایش ساختار مدل AlexNet پیاده‌سازی‌شده
۹	نمودار تغییرات خطا و دقت بر روی مجموعه‌داده ارزیابی در طول فرایند آموزش AlexNet
۱۱	ماتریس آشفتگی داده‌های تست برای مدل AlexNet
۶	نمودار تغییرات خطا و دقت بر روی مجموعه‌داده ارزیابی در طول فرایند آموزش INC-
۱۲	VGGN
۱۳	ماتریس آشفتگی داده‌های تست برای مدل INC-VGGN
۱۶	توزیع کلاس‌ها در داده‌های آموزش
۹	توزیع کلاس‌ها در داده‌های آزمون
۱۷	داده‌افزایی یک تصویر
۱۹	نمودار دقت بر حسب دوره روی داده‌های آموزش و آزمون
۱۹	نمودار خطا بر حسب دوره روی داده‌های آموزش و آزمون
۲۰	ماتریس درهم ریختگی
۲۱	دقت مدل با لایه FC
۲۲	خطای مدل با لایه FC
۲۳	دقت مدل بدون داده‌افزایی
۲۳	خطای مدل بدون داده‌افزایی
۲۵	دقت مدل با بهینه‌ساز Adam
۲۵	خطای مدل با بهینه‌ساز Adam
۲۶	دقت مدل با ۱۰ لایه قابل آموزش
۲۷	خطای مدل با ۱۰ لایه قابل آموزش
۲۷	دقت مدل با ۲۰ لایه قابل آموزش

۲۳	خطای مدل با ۲۰ لایه قابل آموزش	۲۸
۲۴	دقت مدل با ۳۰ لایه قابل آموزش	۲۸
۲۵	خطای مدل با ۳۰ لایه قابل آموزش	۲۹

فهرست جداول

۱	محاسبه معیارهای Accuracy ، Sensitivity و Specificity بر روی مجموعه تست برای
۱۰	مدل AlexNet
۲	محاسبه معیارهای Accuracy ، Sensitivity و Specificity بر روی مجموعه تست برای
۱۳	مدل INC-VGGN

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

۱-۱ آماده‌سازی مجموعه داده

طبق خواسته سوال، ابتدا کلاس *Healthy Rice Leaf*، *Bacterial Leaf Blight*، *Brown Spot* و کلاس *Leaf Blast* برای مراحل بعدی انتخاب شد. سپس با نسبت مشخص شده، دیتاست به سه دسته آموزش، ارزیابی و تست تقسیم شد. در جهت بررسی توزیع هر کلاس، ترجیح داده شد، تعداد اعضای مربوط به هر کلاس نمایش داده شود. و نتایج به شکل زیر حاصل آمد:


$$\text{Leaf Rice Healthy} = 653$$

$$\text{Blight Leaf Bacterial} = 636$$

$$\text{Spot Brown} = 646$$

$$\text{Blast Leaf} = 634$$

همچنین هیستوگرام خواسته شده مربوط به تعداد داده‌های هر کلاس در قسمت زیر نمایش داده شده است:



شکل ۱: نمودار هیستوگرام مربوط به تعداد داده‌های هر کلاس انتخابی از دیتاست *rice-disease-dataset*


۲-۱ پیش‌پردازش داده‌ها

همان‌طور که در فایل کد مشخص شده است، از طریق ماژول transform ابتدا سایز عکس‌ها به ۲۲۴ در ۲۲۴ درآمده است. سپس به تانسور تبدیل شده است. دقت شود که متود ToTensor() به صورت پیش‌فرض، پیکسل‌ها را بین ۰ تا ۱ نگاشت می‌کند. همچنین سه روش ذکر شده در مقاله، برای داده‌افزایی اعمال شده است که این روش‌ها عبارت‌اند از: random scaling، random flipping، random rotating. در واقع با حرکت بر روی تصاویر، برای هر تصویر هر یک از این روش‌ها یک بار اعمال می‌شود و در نتیجه سه تصویر جدید برای آن تولید می‌شود که به تصویر قبلی در دیتاست اولیه افزوده می‌شوند. بنابراین پس از اعمال داده‌افزایی، دیتاست، اندازه‌اش ۴ برابر خواهد شد. ما ترجیح دادیم که چنین کاری انجام دهیم. می‌توانستیم روی یک تصویر تمام این روش‌ها را پشت سر هم اعمال کرده و تنها یک تصویر جدید تولید کنیم، اما بنا به اینکه نتیجه بسیار مطلوبی از لحاظ دقت و صحت دریافت کردیم، این روش را باقی گذاشتیم. دقت شود که تابع random_rotate از طریق یک توزیع یکنواخت، چرخشی در بازه ۳۰- درجه تا ۳۰ درجه اعمال می‌کند. تابع random_flip با احتمال ۰.۵ یک چرخش افقی و با احتمال ۰.۵ یک چرخش عمودی را روی یک عکس خاص اعمال می‌کند. همچنین تابع random_scale از طریق یک توزیع یکنواخت تغییر سایزی با نسبت ۰.۸ تا ۱.۲ روی طول و عرض تصویر اعمال می‌کند.

پیرامون علت انتخاب روش‌های داده‌افزایی، شایان ذکر است که چرخش تصادفی با ایجاد تغییر در زاویه دید، به مدل کمک می‌کند تا نسبت به وضعیت قرارگیری اشیاء حساسیت کمتری داشته باشد. وارون‌سازی افقی و عمودی نیز موجب افزایش تنوع هندسی نمونه‌ها می‌شود و از بیش‌پرازش جلوگیری می‌کند. در نهایت، تغییر مقیاس با شبیه‌سازی تغییرات فاصله یا بزرگ‌نمایی، باعث می‌شود مدل نسبت به تغییرات اندازه اشیاء مقاوم‌تر شود. این مجموعه از تبدیلات، با حفظ ساختار کلی تصویر، تنوع کافی را ایجاد کرده و برای آموزش مدل‌هایی مانند AlexNet مناسب ارزیابی می‌شود.

همچنین در قسمت زیر، همان‌طور که خواسته شد، سه تصویر به صورت تصادفی از مجموعه آموزش انتخاب شد، سپس هر یک از توابع داده‌افزایی بر روی آنها اعمال و سپس تمامی نتایج در یک شکل رسم شد.

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی



شکل ۲: نمودار سه شکل انتخابی اولیه و نتیجه اعمال هر یک روش‌های داده‌افزایی انتخاب‌شده

۳-۱ مدل AlexNet

در قسمت زیر یک summary از مدل AlexNet پیاده‌سازی‌شده نمایش داده است:

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 96, 54, 54]	34,944
ReLU-2	[-1, 96, 54, 54]	0
MaxPool2d-3	[-1, 96, 26, 26]	0
Conv2d-4	[-1, 256, 26, 26]	614,656
ReLU-5	[-1, 256, 26, 26]	0
MaxPool2d-6	[-1, 256, 12, 12]	0
Conv2d-7	[-1, 384, 12, 12]	885,120
ReLU-8	[-1, 384, 12, 12]	0
Conv2d-9	[-1, 384, 12, 12]	1,327,488
ReLU-10	[-1, 384, 12, 12]	0
Conv2d-11	[-1, 256, 12, 12]	884,992
ReLU-12	[-1, 256, 12, 12]	0
MaxPool2d-13	[-1, 256, 5, 5]	0
Dropout-14	[-1, 6400]	0
Linear-15	[-1, 4096]	26,218,496
ReLU-16	[-1, 4096]	0
Dropout-17	[-1, 4096]	0
Linear-18	[-1, 4096]	16,781,312
ReLU-19	[-1, 4096]	0
Linear-20	[-1, 4]	16,388
Total params: 46,763,396		
Trainable params: 46,763,396		
Non-trainable params: 0		

شکل ۳: نمایش ساختار مدل AlexNet پیاده‌سازی‌شده

همچنین طبق خواسته سوال مدل، برای ۳۰ اپیاک بر روی مجموعه داده آموزش داده شد. همچنین فرض ما

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی


بر این بود که تنها نرخ یادگیری نهایی که از طریق تجربه نرخ‌های متفاوت و ارزیابی کیفیت پاسخ‌ها بدست آمده است، نیاز به گزارش دارد.

برای آموزش، از خطای CrossEntropyLoss استفاده شد. این تابع یکی از پرکاربردترین توابع هزینه برای مسائل طبقه‌بندی چندکلاسه است؛ زیرا به‌صورت مستقیم تفاوت میان توزیع احتمال خروجی مدل و توزیع واقعی برچسب‌ها را اندازه‌گیری می‌کند. Cross-Entropy با تشویق مدل به افزایش احتمال کلاس صحیح و کاهش احتمال سایر کلاس‌ها، یادگیری تمایز میان کلاس‌ها را تسهیل می‌کند. علاوه بر این، این تابع با لایه Softmax سازگاری کامل داشته و در معماری‌هایی مانند AlexNet، که برای طبقه‌بندی تصاویر به‌کار می‌روند، به‌عنوان انتخاب پیش‌فرض و بهینه شناخته می‌شود.

همچنین بهترین نرخ یادگیری بدست آمده، طبق اجراهای گوناگون، برابر ۰.۰۰۰۱ بود.

همچنین batch_size برابر با ۳۲ در نظر گرفته شد. این مقدار یکی از مقادیر رایج و استاندارد در آموزش شبکه‌های عمیق است؛ زیرا توازن مناسبی میان پایداری گرادینان و کارایی محاسباتی ایجاد می‌کند. اندازه‌های بسیار کوچک موجب نوسان شدید گرادینان و کندی همگرایی می‌شوند، در حالی که اندازه‌های بسیار بزرگ نیازمند حافظه بالا بوده و به کاهش قدرت تعمیم مدل منجر می‌شوند.

همچنین نمودار خواسته‌شده برای نظارت فرآیند آموزش در قسمت زیر نمایش داده شده است:



شکل ۴: نمودار تغییرات خطا و دقت بر روی مجموعه داده ارزیابی در طول فرآیند آموزش AlexNet

همان طور که مشخص است، شیب تغییرات، نشان‌دهنده این است که یادگیری به‌درستی اتفاق افتاده است. هرچند نوساناتی در طول یادگیری اتفاق افتاده است که می‌توان با تغییر هایپرپارامترها، این مسئله را به‌میزانی کنترل کرد. همچنین معیارهای ذکر شده در مسئله، برای مجموعه داده تست محاسبه و نتایج نهایی در جدول زیر

آمده است:

جدول ۱: محاسبه معیارهای Accuracy، Sensitivity و Specificity بر روی مجموعه تست برای مدل AlexNet

Specificity	Sensitivity	Accuracy	Class
۰.۹۹۳۰۵۶	۱.۰۰۰۰۰۰	۰.۹۹۴۸۱۹	Leaf Rice Healthy
۰.۹۷۷۶۹۵	۰.۹۲۳۰۷۷	۰.۹۶۱۱۴۰	Blight Leaf Bacterial
۰.۹۶۴۴۰۱	۰.۹۷۴۰۲۶	۰.۹۶۶۳۲۱	Spot Brown
۰.۹۷۹۴۵۲	۰.۸۵۱۰۶۴	۰.۹۴۸۱۸۷	Blast Leaf
۰.۹۷۸۶۵۱	۰.۹۳۷۰۴۲	۰.۹۶۷۶۱۷	Average

در ارزیابی عملکرد مدل‌های طبقه‌بندی، شاخص‌های مختلفی برای سنجش دقت و کیفیت پیش‌بینی استفاده می‌شود. در این بخش، مفهوم هر یک از شاخص‌های مورد استفاده در نتایج مدل به‌صورت خلاصه بیان می‌شود:

۱. دقت (Accuracy) این شاخص نشان می‌دهد که مدل در مجموع چه میزان از نمونه‌ها را به‌درستی طبقه‌بندی کرده است. دقت نسبت تعداد پیش‌بینی‌های صحیح به کل نمونه‌هاست. هرچه مقدار Accuracy بیشتر باشد، عملکرد کلی مدل بهتر ارزیابی می‌شود.


۲. حساسیت (Sensitivity) حساسیت بیان می‌کند که مدل تا چه اندازه قادر است نمونه‌های مثبت واقعی را به‌درستی شناسایی کند. این شاخص به‌ویژه زمانی اهمیت دارد که نتوان تشخیص درست نمونه مثبت را نادیده گرفت (مثلاً در تشخیص بیماری). مقدار بالاتر Sensitivity نشان‌دهنده توانایی بیشتر مدل در کشف موارد مثبت است.

۳. ویژگی (Specificity) ویژگی نشان می‌دهد مدل چه میزان از نمونه‌های منفی را به‌درستی تشخیص می‌دهد. این شاخص اهمیت زیادی زمانی دارد که مثبت تشخیص دادن اشتباه مسئله‌ساز باشد. مقدار بالاتر Specificity بیانگر کاهش خطای مثبت کاذب است و نشان می‌دهد مدل توانایی خوبی در تشخیص موارد منفی دارد. حال دقت شود که در تعریف این مفاهیم فرض کردیم که حالت ساده دوکلاسه مد نظر است. برای حالت چندکلاسه که اتفاقاً کیس ما هم به این شکل هست، مسئله مثبت یا منفی بودن یک کلاس، به عضو یک کلاس بودن (مثبت) یا عضو آن کلاس نبودن (منفی) تقلیل می‌ابد.

حال برای تحلیل جدول، مشخص است که میزان میانگین specificity بالاتر از accuracy و آن هم بالاتر از sensitivity قرار گرفته است. که نشان می‌دهد به‌صورت میانگین، مدل در تشخیص اینکه یک عکس، مربوط به کلاس خاصی نیست، از حالتی که بخواهد تشخیص بدهد یک عکس مربوط به کلاس خاصی هست، بهتر عمل کرده است (با یک اختلاف جزئی). همچنین در حالت کلی و با یک نگاه اجمالی، مدل عملکرد خوبی از خودش نشان داده است (به‌نسبت).

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

ماتریس آشفتگی مربوط به این بخش در قسمت زیر آمده است:



شکل ۵: ماتریس آشفتگی داده‌های تست برای مدل AlexNet


همان طور که از ماتریس آشفتگی مشخص است، کلاس Leaf Blast با کلاس Bacterial Leaf Blight بیشترین تداخل را داشته است و مدل در تعیین این جفت کلاس‌ها، در دفعات بیشتری آنها را جای هم تشخیص داده است. گویا مدل در تشخیص این دو جفت کلاس، بیشتر گیج شده است.

حال ذکر چند نکته ضروری است. اولاً فرض شده است که ساختار AlexNet را می‌توانیم به صورت پیوسته و نه لزوماً موازی نیز پیاده‌سازی کنیم. چون در اسلایدهای درس، ساختار موازی نمایش داده شده بود. واضح است که پیاده‌سازی آن ساختار نیز با توجه به امکانات ارائه شده در کتابخانه‌های آماده، پیچیدگی چندانی ندارد. به دلیل سادگی بیشتر در پیاده‌سازی چنین ساختاری انتخاب شده است. همچنین دقت شود که نتایج و تحلیل‌های یادشده، مربوط به یک اجرا از کدها می‌باشد. واضح است که در اجراهای دیگر، ممکن است با توجه به خاصیت تصادفی ذاتی پیاده‌سازی، نتایج اندکی متفاوت باشند.

۴-۱ مدل پیشنهادی مقاله INC-VGGN

۵-۱ پیاده‌سازی

همان‌طور که خواسته شده است، از میانگین و انحراف معیار ImageNet استفاده شد تا نرمال‌سازی بر روی داده‌ها انجام شود. دوباره از طریق ماژول transform این کار بعد از resize کردن انجام شده است. همچنین ساختار مذکور، با توجه به متن مقاله پیاده‌سازی شده است که یک summary از آن در فایل ژوپیتر نمایش داده شده است که بر خلاف قسمت قبلی، با توجه به طولانی‌بودن از ارائه آن صرف نظر شده است. تمامی هایپر پارامترهای تعیین‌کننده نیز به‌مانند مدل AlexNet انتخاب شده است تا پس از دریافت نتایج، مقایسه انجام‌پذیر باشد. بنابراین ابتدا نتایج حاصل از این قسمت که مشابه قسمت قبل هستند را تحلیل و بررسی می‌کنیم.



شکل ۶: نمودار تغییرات خطا و دقت بر روی مجموعه داده ارزیابی در طول فرایند آموزش INC-VGGN

نمودارها و میانگین شیب حاصل‌شده نشان می‌دهد که یادگیری به‌درستی اتفاق افتاده است. اما نکته جالب اینجاست که نسبت به مدل قبل، کمی نوسانات بیشتری مشاهده شده است. اما نتیجه نهایی در دقت و خطا، برای این مدل بهتر بوده است.

حال معیارهای مطلوب را بررسی می‌کنیم:


حال از لحاظ ترتیبی، معیارها به‌مانند قبل شده‌اند. پس می‌توانیم به‌مانند سابق نتایج را تحلیل کنیم: specificity بالاتر از accuracy و آن هم بالاتر از sensitivity قرار گرفته است. که نشان می‌دهد به‌صورت میانگین، مدل در تشخیص اینکه یک عکس، مربوط به کلاس خاصی نیست، از حالتی که بخواهد تشخیص بدهد یک عکس مربوط به کلاس خاصی هست، بهتر عمل کرده است (با یک اختلاف جزئی). همچنین در حالت کلی و با یک نگاه اجمالی،

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

جدول ۲: محاسبه معیارهای Accuracy، Sensitivity و Specificity بر روی مجموعه تست برای مدل INC-VGGN

Specificity	Sensitivity	Accuracy	Class
۱.۰۰۰۰۰۰	۱.۰۰۰۰۰۰	۱.۰۰۰۰۰۰	Leaf Rice Healthy
۰.۹۸۵۱۳۰	۰.۹۷۴۳۵۹	۰.۹۸۱۸۶۵	Blight Leaf Bacterial
۰.۹۹۳۵۲۸	۰.۹۸۷۰۱۳	۰.۹۹۲۲۲۸	Spot Brown
۰.۹۸۶۳۰۱	۰.۹۳۶۱۷۰	۰.۹۷۴۰۹۳	Blast Leaf
۰.۹۹۱۲۴۰	۰.۹۷۴۳۸۶	۰.۹۸۷۰۴۷	Average

مدل عملکرد خوبی از خودش نشان داده است (به نسبت).



شکل ۷: ماتریس آشفتگی داده‌های تست برای مدل INC-VGGN

همان طور که از شکل ماتریس آشفتگی پیداست Leaf Blast با کلاس Bacterial Leaf Blight بیشترین تداخل را داشته است و مدل در تعیین این جفت کلاس‌ها، در دفعات بیشتری آنها را جای هم تشخیص داده است. گویا مدل در تشخیص این دو جفت کلاس، بیشتر گیج شده است.

حال به سوالات مطرح‌شده در تحلیل نهایی نتایج، پاسخ می‌دهیم.

در مورد سرعت یادگیری مدل: بله. آنچنان که از verbose مربوط به خطا و دقت مشخص است، مدل پیشنهادی ثانویه، در تعداد اپیک‌های کمتری، به دقت بالاتری رسیده است و این حتی از نمودارهای مربوط به مدل‌ها در حین آموزش نیز قابل استنتاج است.

در مورد استفاده از یک مدل از پیش آموزش داده‌شده: استفاده از وزن‌های پیش‌آموزش داده‌شده‌ی مدل VGG-19، به‌ویژه زمانی که مجموعه داده‌ی آموزشی محدود است، نقش بسیار مهمی در بهبود عملکرد مدل ایفا می‌کند. این وزن‌ها حاصل یادگیری عمیق شبکه روی مجموعه داده‌ی ImageNet با بیش از یک میلیون تصویر هستند؛ بنابراین مدل در لایه‌های ابتدایی و میانی خود مجموعه‌ای از ویژگی‌های عمومی و بسیار کارآمد مانند لبه‌ها، بافت‌ها، الگوهای محلی و ساختارهای پیچیده را فرا گرفته است. انتقال این ویژگی‌های از پیش آموخته‌شده به مدل جدید باعث می‌شود فرایند آموزش به‌جای شروع از وزن‌های تصادفی، از یک نقطه‌ی آغاز بسیار قوی‌تر شروع شود. در واقع از طریق یادگیری انتقالی، مدل نیاز دارد تنها ویژگی‌های خاصی را بیاموزد و نیازی به یادگیری از پایه نیست. این کار سرعت و عملکرد مدل خالص (بدون یادگیری انتقالی) را بهبود می‌بخشد.

دلیل جایگزینی لایه‌های کانولوشنی انتهایی با دو لایه Inception: در معماری پیشنهادی، لایه‌های انتهایی شبکه‌ی VGG-19 با دو ماژول Inception جایگزین شده‌اند. دلیل این انتخاب آن است که یک لایه کانولوشن کلاسیک تنها قادر است اطلاعات را در یک مقیاس ثابت استخراج کند؛ در حالی که الگوهای بصری موجود در تصاویر برگ‌های برنج، مانند الگوهای رنگی، لکه‌ها، سوختگی‌ها و تغییرات بافت، ممکن است در اندازه‌ها و مقیاس‌های متفاوت ظاهر شوند. این تنوع در الگوها باعث می‌شود استخراج ویژگی در یک مقیاس ثابت ناکافی باشد. ماژول Inception با استفاده هم‌زمان از چندین فیلتر با اندازه‌های مختلف، ویژگی‌ها را در مقیاس‌های چندگانه استخراج می‌کند. ترکیب این ویژگی‌ها، بازنمایی غنی‌تر و کامل‌تری از تصویر فراهم می‌کند.

علاوه بر این، استفاده از مسیرهای موازی در Inception موجب بهبود جریان گرادیان و یادگیری پایدارتر می‌شود، بدون آن‌که افزایش چشمگیری در هزینه محاسباتی ایجاد کند.


دلیل استفاده از Global Pooling به جای لایه‌های FC در لایه انتهایی: طبق درکی که از مقاله بدست آورده ایم، این امر تعداد پارامترهای قابل یادگیری را به‌طور قابل توجهی کاهش می‌دهد. لایه‌های کاملاً متصل معمولاً میلیون‌ها پارامتر دارند و این موضوع احتمال بیش‌برازش را بالا می‌برد، به‌ویژه زمانی که اندازه مجموعه داده کوچک باشد. در مقابل، Global Average Pooling با میانگین‌گیری از هر نقشه ویژگی، یک نمایش بسیار فشرده و پایدار ایجاد می‌کند. حذف لایه‌های FC باعث کاهش مصرف حافظه و هزینه محاسباتی می‌شود و سرعت

۱ سوال اول: تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

استنتاج را افزایش می‌دهد. نتیجه آن است که جایگزینی FC با Global Average Pooling موجب سبک‌تر شدن مدل، افزایش توانایی تعمیم‌دهی و بهبود پایداری آن در وظایف طبقه‌بندی تصاویر می‌شود.

۲-۲ پیش پردازش داده ها

تکنیک داده افزایی برای تصاویر سنجش از دور بسیار حیاتی است چرا که این تصاویر معمولاً توسط پهباد هایی ثبت می‌شوند که در ارتفاع های مختلف و یا زوایای مختلف تصاویر را ثبت میکنند و اگر فقط در یک زاویه به مدل تصاویر را بدهیم مدل به راحتی دچار overfitting می‌شود و همچنین با این متود کمبود داده های آموزش را می‌توان جبران کرد. برای این منظور ما با کمک تابع Augmentations فرایند داده افزایی را انجام می‌دهیم و به ازای هر عکس ۵ تصویر دیگر به داده های آموزش اضافه می‌کنیم. یک نمونه از این تصاویر را در زیر مشاهده می‌کنیم:



شکل ۱۰: داده افزایی یک تصویر

همچنین در کلاس image_generator داده ها را به بچ های ۳۶ تایی برای آموزش تقسیم می‌کنیم و در همین تابع عکس ها را با میانگین و انحراف معیار imageNet نرمال سازی می‌کنیم.


۳-۲ پیاده‌سازی

مدل xception از لایه‌های زیادی برای استخراج ویژگی‌های تصویر استفاده می‌کند و در ادامه به طور خلاصه معماری این مدل را شرح می‌دهیم. بخش اول برای کاهش رزولوشن و استخراج ویژگی‌های اولیه تصویر است که از دو لایه Conv2D استفاده می‌کند و در ادامه سه بلوک تکراری دارد که هر بلوک شامل SeparableConv2D و BatchNormalization ، ReLu Activation و یک لایه Skipconnection است. در بخش بعدی ویژگی‌های پیچیده‌تر استخراج می‌شود و ابعاد تصویر ثابت می‌ماند و شامل ۸ بلوک تکراری که هر بلوک شامل ۳ تا separableConv2D و ۳ تا BatchNormalization و یک SkipConnection است. و بخش آخر هم که بخش خروجی مدل است و شامل MaxPooling، SeparableConv2D و Skipconnection است و ما در ادامه این بخش از MLP برای کلاس بندی ویژگی‌های استخراج شده توسط xception استفاده کردیم که ابتدای این MLP از یک GlobalMaxPooling2D استفاده کردیم و بعد از آن از یک لایه Dense ۲۰۴۸ بعدی (به تعداد خروجی لایه قبل) استفاده کردیم و در انتها یک لایه Softmax با ۲۱ خروجی برای کلاس بندی نهایی قرار دادیم.


این مدل را با نرخ آموزش یک هزارم و یک صدم و یک دهم آموزش دادیم و نرخ آموزش یک صدم بهترین عملکرد را از خودش نشان داد. (البته بدلیل حجم بودن آموزش این نرخ‌ها را در ۲۰ اپیک اول مقایسه کردیم.) همچنین همانطور که بالاتر اشاره کردیم اندازه هر بچ را ۳۶ و در ۵۰ دوره مدل را آموزش دادیم.

۴-۲ ارزیابی

در ادامه نمودار خطا و دقت روی داده های آموزش و آزمون را بررسی می‌کنیم:




شکل ۱۱: نمودار دقت بر حسب دوره روی داده های آموزش و آزمون



شکل ۱۲: نمودار خطا بر حسب دوره روی داده های آموزش و آزمون

همانطور که مشخص است دقت و خطای روی داده های آزمون خیلی نوسانی است و تقریباً بعد از دوره دهم دقت و خطا روی داده های آزمون به صورت میانگین تغییری نکرده ولی روی داده های آموزش حتی بعد از دوره ۴۰ ام هم دقت و خطا رفته رفته بهتر شده و احتمالاً مدل در حال overfitting روی داده های آموزش بوده است. ماتریس درهم ریختگی داده های آزمون به صورت زیر است: کلاس های , chaparral , buildings , agricultural




شکل ۱۳: ماتریس درهم ریختگی

denseresidential , forest , golfcourse , intersection , mediumresidential , parkinglot , river , storagetanks , freeway های کلاس های airplane , freeway ۲۰ درصد خطای تشخیص دارند که بیشترین خطا را بین کلاس ها دارا هستند. کلاس airplane با parkinglot و کلاس freeway با freeway های beach و forest بیشترین تداخل را دارا هستند. (هر کدام ۱۰ درصد)


۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور

در این معماری پیشنهادی سرعت یادگیری بشدت بالاست طوری که مدل تقریباً بعد از دوره پنجم روی داده های آزمون به دقت بالای ۹۰ درصد می‌رسد و در ادامه مدل اکثر کاری که می‌کند افزایش دقت روی داده های آموزش است و می‌توان گفت با افزایش دوره مدل روی نويز های داده آموزش مسلط می‌شود و دقت مدل روی داده های آزمون بعد از ۱۰ دوره بالای ۹۰ درصد تثبیت شده است.

اینبار لایه MLP را حذف میکنیم و از همان FC مدل استفاده میکنیم و نتایج را گزارش میدهیم:



شکل ۱۴: دقت مدل با لایه FC



شکل ۱۵: خطای مدل با لایه FC

همانطور که در نمودار های بالا مشاهده کردیم دقت مدل روی داده های آزمون با لایه FC نوسانی تر از مدل MLP است و بعضی وقت ها دقت مدل زیر ۹۰ درصد هم می‌رسد.


GlobalAveragePooling2D خروجی حجیم CNN را با گرفتن میانگین هر کانال به یک بردار کوچک تبدیل می‌کند تا بتوان آن را به یک MLP یا Dense فید کرد. این روش علاوه بر آماده سازی داده برای ورودی MLP ، باعث کاهش شدید تعداد پارامترها و جلوگیری از overfitting نسبت به روش Flatten می‌شود.

نویسندگان از Adagrad استفاده کردند چون این بهینه ساز برای هر وزن یک نرخ یادگیری متغیر تعیین می‌کند و باعث می‌شود پارامترهای مهمتر مؤثرتر یاد بگیرند، بدون اینکه نیاز به تنظیم دستی learning rate باشد. علاوه براین، Adagrad در داده‌های پراکنده و noisy عملکرد پایدارتری دارد ، که برای داده‌های سنجش از دور بسیار مناسب است.


۵-۲ تحلیل و بهینه سازی

۱-۵-۲ تاثیر داده افزایی

مدل CNN-MLP را بدون داده افزایی برای ۵۰ دوره آموزش دادیم. نتایج آموزش به صورت زیر است:



شکل ۱۶: دقت مدل بدون داده افزایی




شکل ۱۷: خطای مدل بدون داده افزایی

۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور


همانطور که مشخص است بدون داده افزایشی مقداری نوسانات مدل روی داده های آزمون کمتر شده که البته طبیعی است. زیرا با داده افزایشی مدل با پیچیدگی بیشتری مواجه می‌شود و ممکن است یادگیری برایش اندکی سخت تر شود و دلیل این نوسانات به خاطر همین موضوع است. البته داده افزایشی در مجموع قدرت تعمیم یا Generalization مدل را افزایش می‌دهد و روی داده های دنیای واقعی قطعا اثر بخشی بهتری خواهد داشت.

۲-۵-۲ نقش بهینه ساز

اینبار بجای بهینه ساز Adagard از بهینه ساز Adam استفاده کردیم. نتایج به صورت زیر است:



شکل ۱۸: دقت مدل با بهینه ساز Adam




شکل ۱۹: خطای مدل با بهینه ساز Adam

۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور

همانطور که مشخص است نوسانات دقت مدل روی داده های آزمون بسیار زیاد است و همچنین دقت مدل روی داده های آموزش هم به خوبی دقت مدل با بهینه ساز Adagard نیست . همچنین نمدار خطا هم مانند نمودار دقت نوسانات شدیدی دارد. پس واقعا انتخاب این بهینه ساز نقش پر رنگی در دقت بالای مدل دارد و دلیل اصلی انتخاب این مدل توسط نویسنده ها همین بوده است.


۲-۵-۳ بهینه سازی توسط fine-tuning

اینبار بجای فریز کردن تمام لایه ها چند لایه آخر را از فریز خارج می‌کنیم و اجازه می‌دهیم در فرایند یادگیری وزن ها تغییر کنند. بار اول ۱۰ لایه آخر را برای یادگیری از فریز خارج کردیم و دقت و خطا را بدست آوردیم:




شکل ۲۰: دقت مدل با ۱۰ لایه قابل آموزش

۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور




شکل ۲۱: خطای مدل با ۱۰ لایه قابل آموزش

در گام بعدی با ۲۰ و ۳۰ لایه قابل آموزش مدل را آموزش دادیم و نتایج به صورت زیر هستند:




شکل ۲۲: دقت مدل با ۲۰ لایه قابل آموزش


۲ سوال دوم: طبقه‌بندی صحنه در تصاویر سنجش از دور



شکل ۲۳: خطای مدل با ۲۰ لایه قابل آموزش



شکل ۲۴: دقت مدل با ۳۰ لایه قابل آموزش



شکل ۲۵: خطای مدل با ۳۰ لایه قابل آموزش

همانطور که مشخص است هر چقدر عمق لایه های قابل آموزش بیشتر می شود نوسانات مدل روی داده های آموزش بیشتر می شود. روی مدل ۳۰ لایه این نوسانات به خوبی به چشم میخورند. روی مدل های ۱۰ لایه ای و ۲۰ لایه ای هر دو تقریباً از شدت نوسانات یکسانی برخوردارند ولی میانگین دقت مدل ۲۰ لایه ای اندکی بالاتر از میانگین دقت مدل ۱۰ لایه ای است. بنابراین بهترین تعداد لایه را می توانیم عدد ۲۰ گزارش کنیم.