



به نام خدا
دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر



درس شبکه‌های عصبی و یادگیری عمیق

تمرین شماره سه

طراحان تمرین:

محمد جعفری

سوال یک:

مهدی صبوری

سوال دو:

مهلت ارسال: ۱۶ آذر ۱۴۰۴

4	سوال ۱. سگمنتیشن بافت‌های مغزی
7	۱-۱. مجموعه داده
7	۱-۱-۱. تحقیق و توضیح (۱۵ نمره)
7	۱-۱-۲. پارامترها
8	۱-۱-۳. مصورسازی داده‌ها (۱۰ نمره)
8	۱-۲. پیاده سازی معماری مدل (۳۰ نمره)
8	۱-۳. بهینه ساز، تابع هزینه و نحوه شروع وزن‌ها
8	۱-۳-۱. متریک‌ها (۱۵ نمره)
8	۱-۳-۲. مقداردهی اولیه وزن‌ها با روش LECUN (امتیازی: ۵ نمره)
9	۱-۴. آموزش مدل (۱۵ نمره)
9	۱-۵. مصورسازی نتایج (۱۵ نمره)
10	سوال ۲. تشخیص وسایل نقلیه با استفاده از Faster-RCNN بهبود یافته
10	۲-۱. سوالات نظری (۱۵ نمره)
10	۲-۲. مجموعه داده
10	۲-۲-۱. پیش پردازش داده‌ها (۱۵ نمره)
11	۲-۲-۲. مصورسازی داده (۵ نمره)
11	۲-۳. پیاده سازی مدل (۳۰ نمره)
12	۲-۴. آموزش مدل (۲۰ نمره)
12	۲-۵. ارزیابی مدل و مصورسازی نتایج (۱۵ نمره)


- شکل 1. نمونه شبیه سازی سه بعدی برای تصویر سه بعدی یک بیمار و نمایش لیبل‌های (GM: زرد، WM: قهوه ای و CSF: سبز) 5
- شکل 2. نمایش محورهای متنوع پزشکی 6
- شکل 3. بُرش‌ها در محورهای متنوع 6
- شکل 4. یک نمونه از تصاویر دیتاست LSVH 10
- شکل 5. معماری پیشنهادی مقاله 11

7	جدول 1. هایپر پارامترها و مقادیر الزامی
12	جدول 2. هایپر پارامترهای مدل

سوال ۱. سگمنتیشن بافت‌های مغزی

شما در این تمرین، ابتدا با نحوه کار با دیتاست‌های واقعی پزشکی و ناحیه‌بندی^۱ دقیق پیکسل به پیکسل برای بیماران در حوزه پزشکی آشنا خواهید شد، سپس معماری یک شبکه دو بُعدی مبتنی بر U-Net به نام M-Net که برای تسک پیش رو طراحی شده است را پیاده سازی خواهید نمود. مفاهیم ناحیه بندی در کار با تصاویر دو بعدی و مدل معرفی شده است، لذا توجه داشته باشید توضیحات را به دقت مطالعه نموده و سپس پیاده سازی را قدم به قدم انجام دهید. روند این تمرین و مدل ذکر شده مطابق با مقاله پیوست شده و [این لینک](#) می‌باشد.

مجموعه داده انتخاب شده برای این تمرین، [مجموعه دادگان IBSR](#) می‌باشد که تصاویر T1W MRI مغز به همراه لیبل مرتبط می‌باشد که برای ۱۸ بیمار گرفته شده است. (در مقاله از دو مجموعه داده استفاده شده است، شما تنها از دیتاست IBSR استفاده می‌نمایید). برای دسترسی راحت‌تر، لینک این مجموعه داده برای شما در یک پوشه Google Drive که به صورت عمومی در لینک بالا با شما به اشتراک گذاشته شده است. این مجموعه داده شامل ۴ کلاس می‌باشد مطابق با شکل ۱، برچسب‌های ناحیه‌بندی برای درک بهتر شما مصورسازی شده‌اند. این برچسب‌ها شامل بافت سفید مغزی^۲، بافت خاکستری مغزی^۳ و مایع مغزی نخائی^۴ برای یک شخص خاص می‌باشد. هر پیکسل فقط می‌تواند عضو یک کلاس باشد، و هر پیکسلی که جزو کلاس‌های بالا نباشد، جزو کلاس پیش زمینه است.



شکل ۱. نمونه شبیه سازی سه بعدی برای تصویر سه بعدی یک بیمار و نمایش لیبل‌های (GM: زرد، WM: قهوه ای و CSF: سبز)

مجموعه داده شامل ۱۸ تصویر سه بعدی مغز ۱۸ فرد می‌باشد. توجه داشته باشید که Data preparation از جمله نرمال سازی^۵ بر روی این دادگان از قبل انجام شده پس نیازی به نرمال سازی داده نخواهید داشت. در محورهای مختلف در فضای سه بعدی، همانند شکل ۲، تصویر شامل محورهای x و y را axial، تصویر شامل محورهای x و z را coronal و تصویر شامل محورهای y و z را sagittal می‌نامیم. از هر تصویر سه بعدی در هر محور، در برش‌های مختلف تعدادی تصویر دو بُعدی استخراج می‌شود. شبکه این تصاویر دو بُعدی را برای Segmentation به عنوان ورودی دریافت خواهد کرد.


Segmentation¹

White matter²

Grey matter³


CSF⁴

normalization⁵



شکل 2. نمایش محورهای متنوع پزشکی

این دیتاست شامل فایل‌های ۱۸ بیمار به صورت فشرده شده است که شامل تصویر سه بعدی بیمار (جمع‌بندی بیمار در این فایل‌ها حذف شده و Data preparation اعم از نرمال سازی^۶ بر روی این داده‌ها از قبل انجام شده پس نیازی به نرمال سازی داده نخواهید داشت). تصاویر هر بیمار در حوزه سه بعدی می‌باشد که طبق مقاله پیوست شده، ما تصاویر دوبعدی را از آن استخراج کرده و از آن تصاویر دو بعدی برای Segmentation استفاده می‌نماییم. این روند به ما این امکان را می‌دهد تا تعداد تصاویر زیادی را برای آموزش و ارزیابی مدل به دست بیاوریم. به دلیل روند پیچیده و کار با فرمت nifti (.nii.gz) کد قسمت بارگذاری داده در اختیار شما دانشجویان قرار گرفته است. در نهایت، ما عکس‌های مربوطه مطابق با روش توضیح داده شده در مقاله پیوست را پیاده سازی کرده و برای هر شخص در هر محور، حدود ۴۸ تصویر دو بعدی مشابه با شکل ۳ استخراج می‌نماییم.



شکل 3. بُرش‌ها در محورهای متنوع

لازم به ذکر است که داده‌ها را با کتابخانه nibabel لود شده است همچنین نام داده‌هایی که لود مینمایید به صورت زیر است:

Patient volume(main MRI data): IBSR_{patient no.}_ana_strip.nii.gz

Corresponding Segmentation file: IBSR_{patient no.}_segTRI_fill_ana.nii.gz

۱-۱. مجموعه داده

در این قسمت به آماده‌سازی دادگان می‌پردازیم. آماده‌سازی داده درست، به شما این امکان را می‌دهد تا قبل از اجرای شبکه ناحیه‌بند خود، روند ورودی و خروجی دادن بهینه را به نسبت داده‌ها معین نمایید تا از اتلاف وقت و هزینه محاسباتی و بالاتر بردن عملکرد شبکه خود مطمئن شوید.

۱-۱-۱. تحقیق و توضیح (۱۵ نمره)

مقاله پیوست شده را مطالعه نمایید. در خصوص نحوه استخراج تصاویر از حجم سه بُعدی به همراه روند ذخیره سازی با توجه به تکه کد مربوط به مراحل آماده‌سازی در فایل HW3_Q1_dataprep.py که در اختیار شما قرار گرفته، مراحل کلی که برای آماده‌سازی داده انجام شده را توضیح دهید. ابعاد اولیه را گزارش کنید، سپس به صورت دقیق درباره روش patch based training تحقیق کرده و مزایا و معایب آن را توضیح دهید و علت استفاده آن را در مقاله تحلیل کنید.

۱-۱-۲. پارامترها

مطابق با جدول ۱، هایپرپارامترها را انتخاب کرده و داده‌ها را به قسمت آموزش^۷ و اعتبارسنجی^۸ تقسیم نمایید. بدین معنی که به ازای اشخاص در مجموعه دادگان، تقسیم بندی انجام شده و سپس روند نمونه برنامه برای تقسیم بندی اجرا شود و تعداد patch ها و عکس های استخراج شده گزارش شود.

جدول ۱. هایپر پارامترها و مقادیر الزامی

Hyper Parameters	Value
Batch Size	1
Train, Validation	80%-20%
Optimizer	SGD
Learning Rate	0.0001
Loss Function	categorical cross-entropy
Epochs	10

۱-۱-۳. مصورسازی داده‌ها (۱۰ نمره)

برای ۳ بیمار تصادفی، نمونه برش‌های axial و coronal و sagittal (مشابه با شکل ۳) به همراه شماره اسلایس هر کدام و نقشه برچسب‌ها (ماسک بر اساس هر ۴ کلاس پیش زمینه، CSF، WM، GM) را نمایش دهید. هر کلاس را با یک رنگ خاص در یک تصویر نشان داده و مصورسازی کنید. حال این کار را برای داده‌های patch شده (در هر محور یک patch) تکرار نمایید.

۱-۲. پیاده‌سازی معماری مدل (۳۰ نمره)

در ابتدا توضیح کوتاهی در خصوص مدل U-Net برای وظایف ناحیه‌بندی ارائه دهید. استفاده از ساختار رمزگذار و رمزگشا چه کمکی در خصوص ناحیه‌بندی می‌کند؟
مدل M-Net که از زیر شاخه‌های U-Net هست را طبق مقاله پیاده‌سازی نموده و تعداد پارامترهای آموزش پذیر و غیرآموزش پذیر آن را گزارش نمایید.

۱-۳. بهینه‌ساز، تابع هزینه و نحوه شروع وزن‌ها

توجه داشته باشید متریک‌ها برای هر کلاس، به صورت میانگین روی کل داده گزارش شوند، و نه جداگانه برای هر محور. شما بر اساس کل داده‌ها و میانگین همه patch‌ها گزارش می‌نمایید.

۱-۳-۱. متریک‌ها (۱۵ نمره)

متریک‌های Dice coefficient و Jaccard و Precision و Recall را بدون استفاده از توابع آماده و با استخراج TP و FP و ... پیاده‌سازی کنید، هر کدام از این متریک‌ها چگونه عملکرد شبکه را به ما نشان می‌دهند؟

۱-۳-۲. مقداردهی اولیه وزن‌ها با روش LECUN (امتیازی: ۵ نمره)

در متن مقاله‌ی مربوط به سوال، از [این مقاله](#) (در متن مقاله شماره این رفرنس ۲۲ می‌باشد) برای نحوه initialize کردن لایه‌های کانولوشنی دو بعدی استفاده کرده است. وقتی یک شبکه عصبی می‌سازیم، وزن‌های لایه‌ها (مثل فیلترهای کانولوشن) باید یک مقدار اولیه‌ای داشته باشند. اگر همه را صفر یا یک عدد ثابت بگذاریم، شبکه به درستی یاد نمی‌گیرد. اگر هم اعداد تصادفی خیلی بزرگ یا خیلی کوچک باشند، ممکن است در طول آموزش دچار مشکل انفجار گرادینت^۹ یا محو شدن گرادینت^{۱۰} شویم.

روش‌های هوشمند مقداردهی اولیه مانند LeCun، Xavier و He سعی می‌کنند وزن‌ها را طوری تنظیم کنند که سیگنال (و گرادینت‌ها) به خوبی در سراسر شبکه، چه به سمت جلو و چه به سمت عقب، منتشر شوند.

تعداد ورودی‌ها که با fan_in از آن یاد برده می‌شود، نشان می‌دهد که هر نورون در لایه (یا هر نقطه در فیچر مپ خروجی لایه کانولوشن) به چند ورودی متصل است. (n برابر تعداد کانال‌های ورودی، K_h و K_w هم به ترتیب برابر طول کرنل و عرض کرنل هستند)

$$fan_in = n \times K_h \times K_w$$

سپس بر اساس پارامتر بالا انحراف معیار به سادگی از فرمول زیر به دست می‌آید:

$$std = \sqrt{\frac{1}{fan_in}}$$

خوشبختانه، PyTorch یک تابع کمکی داخلی برای محاسبه fan_in دارد به نام `nn.init.calculate_fan_in_and_fan_out`. این تابع fan_in و fan_out را برمی‌گرداند. شما فقط به مقدار اول نیاز دارید. حال با مقدار `std` محاسبه شده و میانگین صفر، برای لایه‌های `conv2d` وزن‌های شروع را اعمال کنید.

۱-۴. آموزش مدل (۱۵ نمره)

حال به آموزش و ارزیابی مدل بپردازید، جهت بررسی کیفیت آموزش و اعتبارسنجی مدل، مقادیر تابع هزینه و متریک‌ها را در هر اپیاک گزارش کنید سپس در انتهای آموزش مدل، نمودار تغییرات بر اساس اپیاک‌ها را برای نمودار `Dice Coefficient (DSC)` (برای هر 3 کلاس مهم در اعتبارسنجی) و نمودار خطا (برای مقایسه روند آموزش و اعتبارسنجی) گزارش نمایید. سپس نتایج عملکرد مدل را تحلیل فرمایید. آیا کلاس `CSF` از دیگر کلاس‌ها نتیجه بهتری داده است؟ با ذکر دلیل و دقت به تصاویر بخش ۱-۱-۳ دلیل پاسخ خود را شرح دهید.

توجه داشته باشید که برای دریافت نمره کامل، مقدار متریک `Dice` روی داده‌های ارزیابی، باید برای `WM` به ۷۰٪، برای `GM` به ۷۳٪، و برای `CSF` به ۵۵٪ برسد.

۱-۵. مصورسازی نتایج (۱۵ نمره)

برای یک شخص تصادفی، تصویر `MRI` خام با در کنار هم قرار دادن ۴ `patch` و تبدیل به اسلایس واقعی، به همراه ماسک (هر کلاس داخل ماسک باشد) و نقشه نتیجه تخمینی شبکه برای سگمنتیشن کلاس‌ها را در یک محور دلخواه (`axial` یا `sagittal` یا `coronal`) مصورسازی کنید و عملکرد شبکه را تحلیل کنید.

سوال ۲. تشخیص وسایل نقلیه با استفاده از Faster-RCNN بهبود یافته


در این سؤال هدف آن است که یک نسخه تعمیم‌یافته از Faster R-CNN را پیاده‌سازی کنیم تا بتواند وسایل نقلیه موجود در جاده را تشخیص داده و موقعیت آن‌ها را تعیین کند. این تمرین یک پیاده‌سازی عملی از تسک تشخیص شیء (Object Detection) است. دیتاست مورد استفاده، [LSVH](#) است و شما باید با استفاده از این دیتاست، مدلی را مطابق با معماری ارائه‌شده در [مقاله](#) پیاده‌سازی کنید.

۱-۲. سوالات نظری (۱۵ نمره)

- با توجه به مقاله مورد نظر، تفاوت NMS و Soft-NMS چیست؟
- مزایا و معایب استفاده از Mobilenet در مقابل VGG16 (مدل backbone استفاده شده در مقاله اصلی faster-rcnn) چیست؟
- معماری context-aware RoI Pooling نسبت به RoI Pooling چه مشکلی را حل میکند.

۲-۲. مجموعه داده

ابتدا لازم است دیتاست موردنظر را توسط لینکی که در اختیار شما قرار گرفته است با محیط Google Drive خود share کنید تا در مراحل بعدی به‌سادگی و بدون محدودیت به آن دسترسی داشته باشید. برای این کار در صفحه دیتاست مورد نظر می‌توانید گزینه add shortcut to Drive را استفاده کنید.



شکل ۴. یک نمونه از تصاویر دیتاست LSVH

۱-۲-۲. پیش پردازش داده‌ها (۱۵ نمره)

دیتاست مورد استفاده در این تمرین شامل کلاس های car, bus, van, don't care است، مربوط به ماشین هایی میباشد که به دلیل ریز و غیر قابل تشخیص بودن توسط انسان به عنوان داده بی اهمیت دسته بندی شده است. برای بررسی بهتر داده میتوانید [مقاله](#) مربوط به این دیتاست را بررسی کنید.

با توجه به اینکه هدف این پروژه طراحی و پیاده سازی مدلی برای تشخیص تمامی انواع وسایل نقلیه است، در مرحله ی پیش پردازش لازم است نمونه های مربوط به کلاس های مختلف وسایل نقلیه از دیتاست انتخاب شوند. درواقع، مدل به تشخیص سواری های مختلف بدون توجه به نوع آن ها خواهد پرداخت. بنابراین تمامی کلاس های غیرمرتبط با مفهوم وسیله ی نقلیه (مانند don't care) حذف شده و Bounding Box های مربوط به تمام انواع وسایل نقلیه (از جمله خودرو سواری، ون، اتوبوس) مطابق با ساختار annotations استخراج و سامان دهی می شوند.

این فرایند باعث می شود داده ی ورودی کاملاً با هدف مسئله هم راستا شده و مدل بتواند در تشخیص یک کلاس کلی با عنوان "vehicle" عملکرد دقیق تری داشته باشد. همچنین در این مرحله باید تصاویری که فاقد هرگونه وسیله ی نقلیه هستند حذف شوند. در پایان نیز لازم است تعداد نهایی نمونه های باقی مانده پس از پیش پردازش گزارش شود.

۲-۲-۲. مصور سازی داده (۵ نمره)

پس از انجام مرحله پیش پردازش، لازم است نمونه ای از داده های آماده سازی شده را بررسی کنید. بدین منظور، تعدادی از تصاویر انتخاب شده را همراه با Bounding Box های مربوط به اشیای موجود در آن را نمایش دهید. این کار به شما امکان می دهد از صحت استخراج باکس ها و کیفیت داده های ورودی پیش از آغاز آموزش مدل اطمینان حاصل کنید.

۳-۲. پیاده سازی مدل (۳۰ نمره)

در این قسمت شما باید طبق شکل ۳، معماری معرفی شده در مقاله را به دقت پیاده سازی کنید. از مدل MobilenetV2 به عنوان backbone استفاده کنید. تعداد پارامترهای قابل آموزش و کل را گزارش کنید.




FIGURE 1: The overall framework of the proposed approach.

شکل 5. معماری پیشنهادی مقاله

۲-۴. آموزش مدل (۲۰ نمره)

در این بخش باید مدل خود را آموزش دهید. برای این منظور، Hyperparameterهای مشخص شده در جدول ۲ را در نظر بگیرید. با توجه به محدودیت‌های سخت‌افزاری و زمان آموزش، پیشنهاد می‌شود ۴۰٪ از داده‌های آموزش و ۲۰٪ از داده‌های تست به صورت تصادفی انتخاب شوند. همچنین در هر epoch مقدار Loss گزارش شود تا روند یادگیری مدل قابل بررسی باشد. علاوه بر این، ۱۰٪ دیگر از داده‌های آموزش به عنوان مجموعه ارزیابی داخلی استفاده شود تا از صحت فرآیند آموزش و عملکرد مدل اطمینان حاصل گردد. دقت شود که برای داده‌های ارزیابی باید ۱۰٪ از داده‌های آموزش را انتخاب کنید.

حین آموزش مدل، مقدار $mAP@50$ بر روی مجموعه داده‌های ارزیابی محاسبه و گزارش شود. mAP (Mean Average Precision) معیاری برای سنجش دقت مدل‌های تشخیص اشیاء است و میانگین مقادیر Precision در آستانه‌های مختلف Intersection over Union (IoU) را نشان می‌دهد. در حالت $mAP@50$ ، پیش‌بینی‌های صحیح به شرطی در نظر گرفته می‌شوند که $IoU \geq 0.5$ باشد. برای تحلیل روند یادگیری مدل، این متریک هر ۱۰ اپیاک محاسبه شده تا تغییرات عملکرد مدل در طول زمان به وضوح قابل مشاهده باشد. انتظار می‌رود این معیار برای داده‌های ارزیابی بیشتر از ۶۰٪ باشد.

جدول ۲. هایپرپارامترهای مدل

Hyper Parameters	Value
Batch Size	8
Optimizer	Adam
Learning Rate	Based on paper
Loss Function	Original Fast-RCNN paper
Epochs	50

۲-۵. ارزیابی مدل و مصور سازی نتایج (۱۵ نمره)

در این قسمت باید ۴ نمونه پیش‌بینی‌های مدل بر روی داده‌های تست ارائه شود تا کیفیت شناسایی و دقت مدل به صورت بصری بررسی شود. همچنین، نمودارهای loss و $mAP@50$ مربوط به فرایند آموزش و اعتبارسنجی نیز نمایش داده شوند تا روند همگرایی مدل و پایداری فرایند آموزش ارزیابی شود. در نهایت عدد $mAP@50$ برای داده‌های تست گزارش شود.