



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین شماره سه

دانشجویان:

سوال اول: علی رجب زاده ۸۱۰۱۰۴۱۳۷

سوال دوم: رضا مرید شوشتری ۸۱۰۱۰۴۲۵۰

فهرست مطالب

۴	فهرست تصاویر
۵	فهرست جداول
۶	۱ سوال اول: سگمنتیشن بافت های مغزی
۶	۱-۱ مجموعه داده
۶	۱-۱-۱ تحقیق و توضیح
۷	۱-۱-۲ پارامترها
۸	۱-۱-۳ مصورسازی داده ها
۹	۱-۲ پیاده سازی معماری مدل
۱۰	۱-۳ بهینه ساز، تابع هزینه و نحوه شروع وزن ها
۱۰	۱-۳-۱ متریک ها
۱۱	۱-۳-۲ مقداردهی اولیه وزن ها با روش LECUN
۱۱	۱-۴ آموزش مدل
۱۳	۱-۵ مصورسازی نتایج
۱۴	۲ سوال دوم : تشخیص وسایل نقلیه با استفاده از الگوریتم Faster-RCNN بهبود یافته
۱۴	۱-۲ سوالات نظری
۱۴	۱-۱-۲
۱۴	۱-۲-۲
۱۵	۱-۳-۲
۱۵	۱-۲-۲ مجموعه داده
۱۵	۱-۲-۲ پیش پردازش داده ها
۱۶	۱-۲-۲ مصور سازی داده
۱۷	۱-۳-۲ پیاده سازی مدل
۱۷	۱-۴ آموزش مدل

۵-۲ ارزیابی مدل و مصور سازی نتایج ۱۸

فهرست تصاویر

۱	مصورسازی یک نمونه داده در جهت یک محور نمونه قبل و بعد از انجام patch	۸
۲	نمودار خطا برای مجموعه آموزش و ارزیابی	۱۱
۳	نمودار Dice Coefficient برای سه کلاس مهم اعتبارسنجی	۱۲
۴	مصورسازی نتیجه مدل برای یک نمونه تصادفی	۱۳
۵	چند نمونه از تصاویر به همراه Bounding Box	۱۶
۶	چند نمونه از تصاویر حذف شده	۱۷
۷	نتایج آموزش مدل	۱۸
۸	پیشبینی مدل روی ۴ تا از داده های تست	۱۹

فهرست جداول

۱	خلاصه‌سازی نتایج محاسبه متریک‌ها برای ایپاک نهایی (دهم)	۱۲
---	---	----

۱ سوال اول: سگمنتیشن بافت های مغزی

۱-۱ مجموعه داده

۱-۱-۱ تحقیق و توضیح

داده‌های مورد استفاده در این پژوهش از مجموعه‌داده IBSR تشکیل شده‌اند که شامل تصاویر سه‌بعدی MRI مغز و برچسب‌های قطعه‌بندی متناظر می‌باشند. هر تصویر ورودی به‌صورت یک حجم سه‌بعدی با ابعاد اولیه متفاوت در هر محور فضایی ذخیره شده است. بنابراین، به‌منظور امکان‌پذیر ساختن آموزش شبکه‌های عصبی کانولوشنی دوبعدی، تصاویر سه‌بعدی ابتدا به برش‌های دوبعدی تبدیل شدند.

برای این منظور، از هر حجم سه‌بعدی، برش‌هایی در سه راستای اصلی (محورهای axial، sagittal و coronal) استخراج گردید. فرآیند استخراج برش‌ها به‌گونه‌ای طراحی شد که از هر محور، تعدادی برش با فاصله یکنواخت انتخاب شود و از نواحی مرکزی حجم داده تمرکز بیشتری صورت گیرد. این کار به‌منظور کاهش اثر نواحی کم‌اطلاعات در لبه‌های حجم انجام شد.

پس از استخراج هر برش دوبعدی، عملیات چرخش به اندازه ۹۰ درجه اعمال گردید تا هم‌استاسازی فضایی تصاویر در کل داده‌ها حفظ شود. سپس، به‌دلیل تفاوت ابعاد برش‌های استخراج‌شده، هر تصویر و نقشه برچسب متناظر آن به ابعاد ثابت 256×256 با استفاده از zero-padding متقارن تغییر اندازه داده شد. در این مرحله، هیچ‌گونه تغییر مقیاس یا interpolation روی داده‌ها انجام نشده و تنها از پرکردن نواحی خالی با مقدار صفر استفاده گردید.

پس از آماده‌سازی برش‌های دوبعدی با ابعاد ثابت، هر تصویر 256×256 به چهار پچ غیرهم‌پوشان با ابعاد 128×128 تقسیم شد. به‌طور مشابه، نقشه‌های برچسب نیز با همان الگو به پچ‌های متناظر تقسیم گردیدند. بدین ترتیب، هر نمونه آموزشی شامل یک پچ تصویری تک‌کاناله با ابعاد 128×128 و یک ماسک قطعه‌بندی با همان ابعاد می‌باشد.

این رویکرد که تحت عنوان Patch-Based Training شناخته می‌شود، دارای مزایا و معایب مشخصی است. از جمله مزایای این روش می‌توان به کاهش قابل توجه مصرف حافظه، افزایش تعداد نمونه‌های آموزشی مؤثر، و امکان آموزش شبکه‌های عمیق‌تر با سخت‌افزار محدود اشاره کرد. همچنین، این روش باعث تمرکز مدل بر الگوهای محلی با جزئیات بالا می‌شود که در مسئله قطعه‌بندی بافت‌های مغزی اهمیت ویژه‌ای دارد.

در مقابل، یکی از معایب اصلی آموزش مبتنی بر پیچ، از دست رفتن اطلاعات زمینه‌ای (Global Context) تصویر کامل است. از آنجا که هر پیچ به صورت مستقل پردازش می‌شود، مدل اطلاعاتی از موقعیت مطلق پیچ در ساختار کلی مغز در اختیار ندارد. با این حال، در این پژوهش با استخراج پیچ‌ها از هر سه محور فضایی و از برش‌های متعدد، تلاش شده است تا این محدودیت تا حدی جبران شود.

با توجه به ابعاد بالای داده‌های سه‌بعدی MRI، استفاده از آموزش مبتنی بر پیچ به عنوان یک راهکار عملی و مؤثر انتخاب گردید. این رویکرد امکان آموزش پایدار شبکه M-Net را فراهم نموده و در عین حال، کیفیت قطع‌بندی قابل قبولی را ارائه می‌دهد.

۱-۱-۲ پارامترها

ابتدا توضیحی سطح بالا پیرامون نحوه تشکیل دیتاست‌های آموزش و ارزیابی نهایی ارائه می‌دهیم. به دلیل تفاوت ساختار مسیر فایل‌ها در محیط‌های اجرایی مختلف، به ویژه هنگام استفاده از پلتفرم Kaggle، مجموعه‌ای از مسیرهای احتمالی برای محل ذخیره مجموعه‌داده IBSR در نظر گرفته شد. این مسیرها شامل مسیر پیش فرض ورودی‌های Kaggle، مسیر کاری محلی و مسیر کاری موقت می‌باشند. در ابتدای فرآیند، با بررسی وجود این مسیرها، مسیر صحیح مجموعه‌داده به صورت خودکار شناسایی می‌شود.

پس از شناسایی ریشه مکان ذخیره سازی مجموعه‌داده، فایل‌های تصویری و فایل‌های برچسب قطع‌بندی با استفاده از الگوهای جستجوی glob استخراج شدند. ساختار پوشه‌های مجموعه‌داده به گونه‌ای است که هر نمونه (Case) دارای یک تصویر MRI نواری‌دار شده و یک فایل قطع‌بندی متناظر می‌باشد.

برای هر فایل، شناسه عددی نمونه با استفاده از عبارات منظم (Regular Expressions) از مسیر فایل استخراج شده و سپس دو دیکشنری مجزا برای تصاویر حجمی و نقشه‌های برچسب ایجاد گردید. در این دیکشنری‌ها، کلید هر عنصر شناسه نمونه و مقدار آن مسیر فایل متناظر می‌باشد. این ساختار امکان تطبیق دقیق بین تصاویر و برچسب‌ها را فراهم می‌سازد.

در مرحله بعد، مسیر تصاویر و برچسب‌ها بر اساس شناسه نمونه با یکدیگر جفت‌سازی شدند. بدین منظور، تمامی شناسه‌های موجود استخراج شده و برای هر شناسه، مسیر تصویر و مسیر فایل قطع‌بندی متناظر در قالب یک زوج (Pair) ذخیره گردید. این مرحله تضمین می‌کند که داده‌های ورودی و خروجی شبکه به درستی هم‌تراز باشند.

پس از جفت‌سازی فایل‌ها، مجموعه‌داده به دو بخش آموزش و اعتبارسنجی تقسیم شد. این تقسیم‌بندی در سطح

نمونه‌های سه‌بعدی انجام گردید، به‌طوری‌که تمامی برش‌ها و پچ‌های استخراج‌شده از یک حجم سه‌بعدی، منحصرأً در یکی از دو مجموعه آموزش یا اعتبارسنجی قرار می‌گیرند. این رویکرد از نشت اطلاعات (Data Leakage) بین مجموعه‌ها جلوگیری می‌کند و ارزیابی منصفانه‌تری از عملکرد مدل ارائه می‌دهد.


در این پژوهش، تعداد نمونه‌های اعتبارسنجی به‌صورت ثابت (برابر ۶ عدد) انتخاب شد تا تعادل مناسبی بین آموزش و ارزیابی برقرار گردد.

در نهایت، با استفاده از مسیر فایل‌های مربوط به هر بخش، نمونه‌های آموزشی و اعتبارسنجی از طریق کلاس IBSRPatchDataset ساخته شدند. این کلاس مسئول استخراج برش‌ها، اعمال پیش‌پردازش‌ها و تولید پچ‌های دوبعدی مورد استفاده در فرآیند آموزش شبکه عصبی می‌باشد.

همانطور که در فایل ژوپیتتر انجام شده است، ۶ نمونه به‌عنوان نمونه ارزیابی انتخاب شده است و ۱۲ نمونه، نمونه‌های آموزش هستند. تعداد ۶۵۲۸ پچ برای بخش آموزش و تعداد ۳۲۶۴ پچ برای بخش ارزیابی استخراج شد.

۳-۱-۱ مصورسازی داده‌ها

خواسته سوال، در فایل ژوپیتتر نوتیوک انجام شده است. همچنین تصویر حاصله در قسمت زیر نمایش داده شده است: (دقت شود که در تمام مراحل مصورسازی، رنگ سیاه برای background، رنگ قرمز برای CSF، رنگ سبز برای GM و رنگ آبی برای WM انتخاب شده است.)



شکل ۱: مصورسازی یک نمونه داده در جهت یک محور نمونه قبل و بعد از انجام patch

به دلیل پرهیز از افزونگی، تنها شکل نمونه داده و در جهت یک محور نمونه آورده شده است. طبیعی است که باقی اشکال نیز مبتنی بر همین منطق، در فایل ژوپیتز آمده اند و قابل مشاهده هستند. برای هر نمونه، برش های دوبعدی در راستای سه محور آناتومیکی اصلی شامل Sagittal، Coronal و Axial استخراج شدند. به منظور اجتناب از نواحی کم اطلاعات در ابتدا و انتهای حجم، اندیس برش ها به صورت تصادفی از ناحیه ی مرکزی هر حجم انتخاب گردید. سپس، به منظور یکسان سازی جهت گیری و ابعاد فضایی، برش ها چرخانده شده و با صفر تا اندازه ی ثابت 256×256 پیکسل padding شدند.

در مرحله ی بعد، هر برش به چهار پچ غیر هم پوشان با اندازه ی 128×128 تقسیم شد. این فرآیند به صورت هم زمان بر روی تصویر شدت و نقشه ی برجسب اعمال گردید تا هم تراز ی مکانی بین داده ی ورودی و خروجی حفظ شود. این نحوه ی تقسیم بندی دقیقاً متناظر با ساختار داده های مورد استفاده در فرآیند آموزش شبکه است. برای افزایش قابلیت تفسیر بصری، نقشه های برجسب به صورت تصاویر رنگی RGB نمایش داده شدند، به گونه ای که پس زمینه، مایع مغزی نخاعی (CSF)، ماده ی خاکستری (GM) و ماده ی سفید (WM) با رنگ های متمایز مشخص گردیدند. برای هر محور آناتومیکی، تصویر برش کامل، نقشه ی برجسب متناظر، پچ های استخراج شده و ماسک های هر پچ در قالب یک چیدمان منظم به نمایش درآمدند.

۱-۲ پیاده سازی معماری مدل

U-Net یک معماری شبکه ی عصبی کانولوشنی است که به طور ویژه برای مسائل Semantic Segmentation تصاویر پزشکی طراحی شده است. این شبکه شامل دو بخش اصلی است: Encoder و Decoder. بخش Encoder از لایه های کانولوشن و Pooling تشکیل شده و مسئول استخراج ویژگی های سطح بالا از تصویر ورودی است، که موجب یادگیری الگوهای پیچیده ی بافتی می شود. بخش Decoder با استفاده از لایه های Upsampling و کانولوشن، ویژگی های فشرده شده را به ابعاد اصلی تصویر باز می گرداند و نقشه ی کلاس ها را تولید می کند. اتصالات مستقیم (Skip Connections) بین لایه های متناظر Encoder و Decoder اطلاعات مکانی دقیق را حفظ کرده و دقت تفکیک پذیری پیکسل به پیکسل را افزایش می دهند.

ساختار Encoder-Decoder برای مسائل Segmentation به دو دلیل اصلی مفید است. اول، بخش Encoder ویژگی های چند مقیاسی شامل بافت ها و ساختار های مکانی مهم را استخراج می کند. دوم، بخش Decoder با استفاده از اطلاعات فشرده شده، نقشه ی پیش بینی شده را باز سازی می کند و با اتصالات Skip جزئیات مکانی مانند

مرزهای بافت ها حفظ می شوند. به طور خلاصه، این ساختار امکان تولید نقشه های تقکیک پذیری دقیق و همزمان حفظ جزئیات مکانی را فراهم می کند که برای تصاویر پزشکی با ساختارهای پیچیده بسیار حیاتی است.

۳-۱ بهینه ساز، تابع هزینه و نحوه شروع وزن ها

۱-۳-۱ متریک ها

همان طور که خواسته شد، کلاس SegmentationMetrics برای محاسبه متریک ها در طول آموزش نوشته شده است. این کلاس اجازه می دهد که: معیارها را برای هر کلاس جداگانه گزارش کنیم. به صورت تجمعی روی تمام داده ها محاسبه شود. از معیارها برای مانیتور کردن آموزش شبکه یا ارزیابی کیفیت پیش بینی ها استفاده شود. هر یک از معیارهای Precision، Recall، Jaccard Index و Dice Coefficient به شکلی متفاوت کیفیت عملکرد شبکه در مسائل Segmentation را نشان می دهند.

هر یک از معیارهای Precision، Recall، Jaccard Index و Dice Coefficient به شکلی متفاوت کیفیت عملکرد شبکه در مسائل Segmentation را نشان می دهند.

Recall نشان می دهد چه درصدی از پیکسل های واقعی هر کلاس به درستی توسط شبکه شناسایی شده اند و بیانگر توانایی شبکه در پوشش دادن تمام نمونه های کلاس است. مقدار بالا نشان دهنده کمی بودن False Negative و شناسایی کامل بافت هاست. فرمول Recall به صورت زیر است:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Precision میزان صحت پیکسل های پیش بینی شده را ارزیابی می کند؛ یعنی چه درصدی از پیکسل هایی که شبکه به عنوان یک کلاس مشخص پیش بینی کرده، واقعاً متعلق به همان کلاس هستند. مقدار بالای Precision نشان دهنده کمی بودن False Positive است. فرمول Precision به صورت زیر است:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Jaccard Index یا Intersection over Union میزان همپوشانی بین پیکسل های پیش بینی شده و واقعی را نشان می دهد و معیار کلی تری برای دقت شبکه ارائه می دهد. مقدار نزدیک به یک بیانگر تطابق بالا بین پیش بینی

۱ سوال اول: سگمنتیشن بافت های مغزی

و برچسب واقعی است. فرمول Jaccard به صورت زیر است:

$$\text{Jaccard} = \frac{TP}{TP + FP + FN}$$

Dice Coefficient نیز مشابه Jaccard عمل می‌کند ولی با تأکید بیشتر بر روی True Positive ها و برای تصاویر پزشکی بسیار رایج است. مقدار بالای Dice نشان‌دهنده کیفیت بالای شبکه در شناسایی و جداسازی بافت‌های مختلف است. فرمول Dice به صورت زیر است:


$$\text{Dice} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

۱-۳-۲ مقداردهی اولیه وزن‌ها با روش LECUN


این امر با کمک تعریف تابع `lecun_initialize` و اعمال آن انجام شده است.

۱-۴ آموزش مدل

آموزش مدل، طبق خواسته سوال انجام شد و نمودارهای زیر حاصل آمد:



شکل ۲: نمودار خطا برای مجموعه آموزش و ارزیابی



شکل ۳: نمودار Dice Coefficient برای سه کلاس مهم اعتبار سنجی

همچنین نتیجه محاسبه متریک‌ها برای ایپاک نهایی به شکل زیر است:

جدول ۱: خلاصه‌سازی نتایج محاسبه متریک‌ها برای ایپاک نهایی (دهم)

Recall	Precision	IoU	Dice	Tissue
۱.۰۰۰۰	۰.۹۹۹۰	۰.۹۹۹۰	۰.۹۹۹۵	Background
۰.۴۷۸۲	۰.۸۳۷۶	۰.۴۳۷۶	۰.۶۰۸۸	CSF
۰.۷۹۵۸	۰.۸۵۳۹	۰.۷۰۰۴	۰.۸۲۳۸	GM
۰.۹۰۶۲	۰.۷۴۰۴	۰.۶۸۷۷	۰.۸۱۵۰	WM

همانطور که نمودار خطا نشان می‌دهد یادگیری به‌درستی اتفاق افتاده است و این عملکرد نسبتاً خوب مدل را در فهم الگوها نشان می‌دهد. همچنین پایین‌ترین Dice مربوط به کلاس CSF است. نتایج به‌دست آمده از مدل نشان می‌دهد که بیشترین دقت و Dice مربوط به پس‌زمینه (Background) (که به نوعی برای ما بی‌اهمیت است) و بیشترین دقت برای ماده‌ی خاکستری (GM) و ماده‌ی سفید (WM) است. با این حال، CSF دارای کمترین مقدار Dice و IoU است. این کاهش عملکرد برای CSF معمولاً به دلایل زیر رخ می‌دهد:

۱. CSF نسبت به GM و WM حجم کمتری در تصاویر دارد، بنابراین مدل داده‌های کمتری برای یادگیری ویژگی‌های آن دارد.

۲. لبه‌ها و مرزهای CSF با سایر بافت‌ها معمولاً ناواضح‌تر هستند و مدل در تشخیص دقیق آن دچار خطا می‌شود.


۳. ناهمواری و تنوع شکل CSF بین بیماران باعث می‌شود که پیش‌بینی آن نسبت به بافت‌های بزرگ‌تر و

همگن (WM و GM) سخت‌تر باشد.

به همین دلایل، مقادیر Precision و Recall برای CSF نیز نسبتاً پایین‌تر است، به‌ویژه Recall که نشان‌دهنده‌ی تشخیص ناقص نمونه‌های CSF توسط مدل است.

۵-۱ مصورسازی نتایج

خواسته سوال انجام شده است و در قسمت زیر میتوان شکل مربوط به آن را مشاهده نمود: (دقت شود که در تمام مراحل مصورسازی، رنگ سیاه برای background ، رنگ قرمز برای CSF ، رنگ سبز برای GM و رنگ آبی برای WM انتخاب شده است.)



شکل ۴: مصورسازی نتیجه مدل برای یک نمونه تصادفی

همانطور که مشخص است، مدل عملکرد نسبتاً خوبی از خود نشان داده است اما همان طور که در قسمت قبل، تحلیلی برای آن انجام شد، مدل در تشخیص کلاس CSF با دلایل یادشده، بیشتری مشکل را دارد و گویا در نسبت با باقی کلاس‌ها، در این کلاس ناتوان‌تر رفتار میکند!

۲ سوال دوم : تشخیص وسایل نقلیه با استفاده از الگوریتم Faster-RCNN

بهبود یافته

۱-۲ سوالات نظری

۱-۱-۲

NMS و Soft-NMS هر دو روش‌هایی برای حذف پیش‌بینی‌های اضافی یا تکراری در تشخیص شی هستند، ولی تفاوت آن‌ها در نحوه حذف کردن پیش‌بینی‌های اضافی است:

NMS معمولی:

وقتی چند جعبه (bounding box) روی یک شی پیش‌بینی می‌کند، اون جعبه‌ای که بیشترین احتمال (score) رو داره نگه می‌دارد و بقیه را کامل حذف می‌کند.

مشکل این روش این است که ممکن است بعضی از جعبه‌های خوب که همپوشانی کمی دارند را حذف کند و دقت کم شود.

Soft-NMS:

به جای حذف کامل جعبه‌های تکراری، مقدار score آن‌ها را بسته به همپوشانی کم می‌کند. درواقع در این روش جعبه‌ها کاملاً حذف نمی‌شوند و فقط احتمال آن‌ها کم می‌شود و مدل انعطاف پذیر تر میشود.

۲-۱-۲

استفاده از MobileNet به جای VGG16 به عنوان backbone در مدل‌های Faster R-CNN مزایا و معایبی دارد:

مزایا:

- سبک و سریع: MobileNet طراحی شده تا وزن مدل و محاسبات کمتری داشته باشد، بنابراین زمان آموزش کاهش می‌یابد.
- مناسب برای محیط محدود: برای استفاده در دستگاه‌های mobile یا سیستم‌هایی با حافظه و قدرت پردازشی کم، گزینه بهتری است.

معایب:

- دقت کمتر: به طور کلی، VGG16 به خاطر معماری عمیق‌تر و پیچیده‌تر، ممکن است دقت بالاتری نسبت به MobileNet بدهد، مخصوصاً در تشخیص اشیاء کوچک یا پیچیده.
- استخراج کمتر اطلاعات: MobileNet به دلیل ساختار سادتر، ممکن است ویژگی‌های تصویر را به اندازه VGG16 به طور کامل استخراج نکند.

۳-۱-۲

- در RoI Pooling معمولی، هر region of interest به ابعاد ثابت تبدیل می‌شود و اطلاعات پیرامونی که می‌تواند در تشخیص دقیق شئی کمک کند، از دست می‌رود.
- Context-aware RoI Pooling سعی می‌کند علاوه بر اطلاعات داخل RoI، اطلاعات محیطی اطراف آن را هم حفظ کند تا ویژگی‌های استخراج شده غنی‌تر و دقیق‌تر باشند.

۲-۲ مجموعه داده

۱-۲-۲ پیش پردازش داده ها

اطلاعات فایل LSVH.zip را خواندیم و در ابتدا تعداد فایل ها ۱۴۳۸۸ بود و بعد از حذف باکس های کلاس ۴ و حذف تصاویر خالی از باند تعداد نهایی عکس ها ۱۳۹۳۸ تا شد.

۲ سوال دوم : تشخیص وسایل نقلیه با استفاده از الگوریتم Faster-RCNN بهبود یافته

۲-۲-۲ مصور سازی داده

در ادامه چند نمونه از تصاویر بعد از حذف باکس های کلاس ۴ را مشاهده می کنیم:



شکل ۵: چند نمونه از تصاویر به همراه Bounding Box

همینطور که مشخص است خودرو ها و به خوبی مشخص شده اند.

در ادامه چند تا از تصاویری حذف کردیم را نمایش می دهیم:

۲ سوال دوم : تشخیص وسایل نقلیه با استفاده از الگوریتم Faster-RCNN بهبود یافته



شکل ۶: چند نمونه از تصاویر حذف شده

همانطور که مشخص است تصاویری که حذف شده اند فقط دارای کلاس ۴ بوده اند.

۳-۲ پیاده سازی مدل


مدل را طبق معماری معرفی شده در مقاله ساختیم و فقط از ROI-Polling خود Faster-RCnn بجای context-aware RoI Polling معرفی شده در مقاله استفاده کردیم. در این مدل کل پارامتر ها 82,363,231 است که از این مقدار در هر دوره 80,139,359 از آن ها در حال آموزش هستند و البته بعد از ۱۰ اپیاک وزن های مدل backbone را هم از حالت فریز خارج می کنیم که آن ها هم fine-tune شوند.

۴-۲ آموزش مدل


مدل را با توجه به هایپر پارامتر های مقاله و صورت مسئله آموزش دادیم و فقط بدلیل طولانی بودن زمان آموزش و قطع و وصلی زیاد کگل و کولب مجبور به ران چندین و چند باره این مدل شدیم و در بار های آخر مدل را برای ۳۰ اپیاک ترین کردیم ولی حداقل مقدار $mAP@50$ که صورت سوال خواسته بود را از مدل روی داده های ارزیابی بدست آورده ایم.

۵-۲ ارزیابی مدل و مصور سازی نتایج

نمودار های بدست آمده به صورت زیر هستند.



(ب) مقدار $mAP@50$ در هر ۱۰ دوره



(ا) خطا بر حسب دوره

شکل ۷: نتایج آموزش مدل

همانطور که مشخص است خطا به صورت کلی در روند آموزش کاهشی بوده است که یعنی مدل در حال یادگیری بوده است و همچنین مقدار $mAP@50$ هم افزایشی بوده است و در انتهای دوره سی ام بالای ۸۰ رسیده است که البته مقدار $mAP@50$ خیلی معیار سهل انگارانه ای است و طبیعی است که به همین ارقام بالایی دست پیدا کنیم. در ادامه برای اینکه مدل را روی ۴ تا از تصاویر تست اجرا کنم پلتفرم کرش کرد و بار بعدی فقط برای نمایش همین موضوع مدل را برای ۲۰ دوره آموزش دادم و نتایج به صورت زیر بدست آمد:

۲ سوال دوم : تشخیص وسایل نقلیه با استفاده از الگوریتم Faster-RCNN بهبود یافته

Model Predictions on Test Data



شکل ۸: پیش‌بینی مدل روی ۴ تا از داده‌های تست

همانطور که مشخص است مدل تا حدی توانسته است که باکس‌ها را درست پیش‌بینی کند و البته در بعضی جاها باکس اضافه قرار داده است که ویژگی soft-nms است که همه باکس‌های اضافه را حذف نمی‌کند. اگر مدل را بیشتر هم آموزش دهیم احتمال محل قرار گیری این باکس‌ها بهتر خواهد بود گرچه با همین ۲۰ دوره هم به $\text{mAP}@50$ ۷۰ رسیده ایم. همچنین مقدار $\text{mAP}@50$ روی داده‌های تست با ۲۰ دوره آموزش به عدد ۶۵ رسیده است.