



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین شماره چهار

دانشجویان:

سوال اول: علی رجب زاده ۸۱۰۱۰۴۱۳۷

سوال دوم: رضا مرید شوشتری ۸۱۰۱۰۴۲۵۰

فهرست مطالب

۳	فهرست تصاویر
۴	فهرست جداول
۵	۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری
۵	۱-۱ آماده سازی داده
۶	۲-۱ مدل های پایه
۸	۳-۱ مدل BiLSTM joint
۹	۴-۱ مدل Encoder-Decoder non-aligned joint
۱۳	۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive
۱۳	۱-۲ Data Preprocessing
۱۳	۱-۱-۲
۱۳	۲-۱-۲
۱۵	۳-۱-۲
۱۶	۴-۱-۲
۱۷	۲-۲ مدل پایه
۱۷	۱-۲-۲
۱۸	۲-۲-۲
۱۹	۳-۲ مدل های Recursive Neural Network
۱۹	۱-۳-۲ معماری LSTM
۲۱	۲-۳-۲ معماری GRU
۲۴	۴-۲ مقایسه روی داده های تست و مقایسه عملکرد
۲۴	۱-۴-۲
۲۴	۲-۴-۲

فهرست تصاویر

۶	۱	نمودار تغییرات تابع هزینه برای مدل های BiRNN اتخاذ شده
۶	۲	نمودار تغییرات دقت برای مدل های BiRNN اتخاذ شده
	۳	مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل BiRNN اتخاذ شده
۷		
۸	۴	نمودار تغییرات تابع هزینه برای مدل BiLSTM joint اتخاذ شده
۸	۵	نمودار تغییرات دقت برای مدل BiLSTM joint اتخاذ شده
	۶	مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل BiLSTM joint اتخاذ شده
۹		
۹	۷	نمودار تغییرات تابع هزینه برای مدل Encoder-Decoder non-aligned joint اتخاذ شده
۱۰	۸	نمودار تغییرات دقت برای مدل Encoder-Decoder non-aligned joint اتخاذ شده
	۹	مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل Encoder-Decoder non-aligned joint اتخاذ شده
۱۰		
۱۳	۱۰	نمودار زمانی در کل بازه
۱۴	۱۱	نمودارهای ACF و PACF قبل و بعد از تفاضل گیری برای سری Close
۱۶	۱۲	Histogram توزیع داده های ورودی و خروجی
۱۷	۱۳	تاریخچه Loss در طول آموزش برای Training و Validation روی داده تست
	۱۴	پیش بینی مدل در مقابل قیمت واقعی برای ویژگی های Open, Close, High, Low در بازه ۲۰۲۴-۲۰۲۵
۱۸		
۱۹	۱۵	مقدار loss روی داده های آموزش و ارزیابی
۲۰	۱۶	خلاصه معماری مدل CNN_LSTM با تعداد پارامترها و شکل لایه ها
۲۲	۱۷	مقدار خطا روی داده های آموزش و ارزیابی
۲۳	۱۸	خلاصه معماری CNN - GRU
۲۵	۱۹	پیش بینی قیمت ها برای سال های ۲۰۲۴ تا ۲۰۲۵ با سه مدل مختلف
۲۶	۲۰	پیش بینی قیمت ها برای سال های ۲۰۲۵ تا ۲۰۲۶ با سه مدل مختلف

فهرست جداول

۲۴	مقایسه عملکرد مدل‌ها روی داده‌های تست	۱
۲۴	زمان آموزش و FLOPs تقریبی برای مدل‌ها با epochs=100	۲

۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری

۱-۱ آماده سازی داده

دیتاست لود شده است و تعداد داده های آموزشی برابر ۴۲۷۴ و تعداد داده های تست برابر ۵۸۶ است. همچنین مجموعه دیگری نیز به صورت پیش فرض در دیتاست قرار داده شده بود با نام dev که تعداد داده های آن برابر ۵۷۲ است. سپس طبق خواسته سوال، ۱۰٪ از داده های آموزش برای تشکیل داده های ارزیابی کنار گذاشته شد و سرانجام، در حالت نهایی، تعداد داده های آموزشی برابر ۳۸۴۷ و تعداد داده های ارزیابی برابر ۴۲۷ است. همچنین یک نمونه از داده های آموزشی در فایل ژوینتر به نمایش درآمد که شامل جمله اصلی، برچسب های اسلات و برچسب نیت است.

سپس توکنایز کردن دادگان بر اساس white space انجام شد داده های توکنایز شده در مجموعه دیتاست جایگزین حالت اولیه آنها شد.

سپس مجموعه های واژگان ساخته شد و توکن های <PAD> و <UNK> افزوده شد. دقت شود که این دو توکن تنها به واژگان مربوط به توکن ها (جملات اصلی) و اسلات ها افزوده می شوند و نیازی به افزودن این موارد به واژگان نیات نداریم، زیرا نیت همیشه یک تک کلمه است. تعداد واژگان برای جملات آموزش، برابر ۹۴۷، برای اسلات ها برابر ۱۰۳ و برای نیات برابر ۱۷ است.

<PAD> برای پر کردن جملات کوتاه تر به کار میرود تا همه جملات در یک دسته (batch) طول یکسان داشته باشند. این کار باعث میشود عملیات های برداری در شبکه های عصبی سریع تر و بدون خطا انجام شود. <UNK> برای نمایش کلمات ناشناخته یا کلماتی که در مجموعه آموزش دیده نشده اند استفاده میشود. این تگ به مدل اجازه میدهد با کلمات جدید مواجه شود بدون اینکه خطا رخ دهد.

یکی از روش های رایج برای padding استفاده از طول بیشینه جملات در کل مجموعه داده است. روش دیگری که ما استفاده کردیم، batch-wise padding با کمک PyTorch و collate_fn() است؛ یعنی طول بیشینه فقط برای همان دسته (batch) محاسبه میشود.

مزایای این روش نسبت به padding کل مجموعه داده عبارتند از:

۱. کاهش مصرف حافظه: چون طول padding برابر طول بیشینه دسته است، فضای اضافی برای PAD های غیر ضروری صرف نمیشود.


۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری

۲. افزایش سرعت آموزش : با کاهش تعداد توکن های اضافه، عملیات برداری سریع تر انجام میشود و زمان forward/backward pass کاهش میابد.


۳. بهبود کارایی شبکه : مدل مجبور نیست روی مقادیر PAD یاد بگیرد، پس تمرکز آن روی توکن های واقعی بیشتر میشود.

۲-۱ مدل های پایه

در قسمت زیر، نمودار تغییرات تابع هزینه و دقت روی داده آموزش و ارزیابی برای مدل های BiRNN اتخاذ شده نمایش داده شده است.



شکل ۱: نمودار تغییرات تابع هزینه برای مدل های BiRNN اتخاذ شده



شکل ۲: نمودار تغییرات دقت برای مدل های BiRNN اتخاذ شده

۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری

همچنین طبق نمودارها مشخص است که یادگیری به درستی انجام شده است. مقدار تابع هزینه در طول اپیاک ها به طور نسبی کاهش یافته است و مقدار دقت افزایش یافته است.

همچنین دقت تشخیص نیات روی داده تست، برابر ۰.۹۵۴ است. و مقادیر F1-Score و Classification Report در قسمت زیر نمایش داده شده است:

```
Slot F1 Score: 0.9434440781131118
```


Slot Classification Report:				
	precision	recall	f1-score	support
aircraft_code	1.00	0.29	0.44	7
airline_code	1.00	0.91	0.95	22
airline_name	0.96	0.97	0.96	91
airport_code	0.33	0.25	0.29	4
airport_name	0.56	0.62	0.59	8
arrive_date.date_relative	0.00	0.00	0.00	1
arrive_date.day_name	0.78	0.70	0.74	10
arrive_date.day_number	1.00	1.00	1.00	7
arrive_date.month_name	1.00	1.00	1.00	7
arrive_time.end_time	0.60	1.00	0.75	3
arrive_time.period_mod	0.00	0.00	0.00	1
arrive_time.period_of_day	0.60	0.38	0.46	8
arrive_time.start_time	1.00	0.67	0.80	3
arrive_time.time	0.93	0.82	0.87	17
arrive_time.time_relative	0.83	0.83	0.83	18
city_name	0.80	0.80	0.80	30
class_type	1.00	0.96	0.98	26
connect	1.00	0.60	0.75	5
cost_relative	1.00	1.00	1.00	38
day_name	0.00	0.00	0.00	1
...				
micro avg	0.94	0.94	0.94	1970
macro avg	0.75	0.70	0.71	1970
weighted avg	0.94	0.94	0.94	1970

شکل ۳: مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل BiRNN اتخاذ شده


دلایل استفاده از seqeval در مسائل Sequence Labeling : در این پروژه ما قصد داریم برچسب های توکن به توکن (slot labels) را پیش بینی کنیم، که یک مسئله sequence labeling است. کتابخانه sklearn برای محاسبه معیارهایی مانند F1-score و classification report طراحی شده است، اما این کتابخانه ارتباط توکن ها در داخل یک جمله را در نظر نمی گیرد. seqeval مخصوص مسائل sequence labeling طراحی شده است و می تواند F1-score، دقت و گزارش دسته بندی را بر اساس کل برچسب های جمله محاسبه کند. به عبارت دیگر، seqeval به مدل اجازه می دهد که ساختار جمله و تگ های مرتبط با هم را در ارزیابی لحاظ کند، که برای پیش بینی slot labels اهمیت زیادی دارد.

۳-۱ مدل BiLSTM joint

در قسمت زیر، نمودار تغییرات تابع هزینه و دقت روی داده آموزش و ارزیابی برای مدل BiLSTM joint اتخاذ شده نمایش داده شده است.



شکل ۴: نمودار تغییرات تابع هزینه برای مدل BiLSTM joint اتخاذ شده



شکل ۵: نمودار تغییرات دقت برای مدل BiLSTM joint اتخاذ شده

همچنین طبق نمودارها مشخص است که یادگیری به درستی انجام شده است. مقدار تابع هزینه در طول ایپاک ها به طور نسبی کاهش یافته است و مقدار دقت افزایش یافته است.

همچنین دقت تشخیص نیات روی داده تست، برابر ۰.۹۷۴۴ است. و مقادیر F1-Score و Classification Report در قسمت زیر نمایش داده شده است:

۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری

```
Slot Filling F1 Score:
0.9323193916349809
```


Slot Classification Report:

	precision	recall	f1-score	support
aircraft_code	0.75	0.86	0.80	7
airline_code	0.92	1.00	0.96	22
airline_name	0.97	0.98	0.97	91
airport_code	0.33	0.25	0.29	4
airport_name	0.57	0.50	0.53	8
arrive_date.date_relative	0.50	1.00	0.67	1
arrive_date.day_name	1.00	0.50	0.67	10
arrive_date.day_number	1.00	0.29	0.44	7
arrive_date.month_name	1.00	0.57	0.73	7
arrive_time.end_time	0.00	0.00	0.00	3
arrive_time.period_mod	0.00	0.00	0.00	1
arrive_time.period_of_day	0.71	0.62	0.67	8
arrive_time.start_time	1.00	0.67	0.80	3
arrive_time.time	0.68	0.76	0.72	17
arrive_time.time_relative	0.84	0.89	0.86	18
city_name	0.85	0.77	0.81	30
class_type	0.89	0.96	0.93	26
connect	1.00	0.80	0.89	5
cost_relative	1.00	1.00	1.00	38
...				
micro avg	0.93	0.93	0.93	1970
macro avg	0.77	0.69	0.71	1970
weighted avg	0.93	0.93	0.93	1970

شکل ۶: مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل BiLSTM اتخاذشده


۴-۱ مدل Encoder-Decoder non-aligned joint

در قسمت زیر، نمودار تغییرات تابع هزینه و دقت روی داده آموزش و ارزیابی برای مدل Encoder-Decoder non-aligned joint اتخاذشده نمایش داده شده است.



شکل ۷: نمودار تغییرات تابع هزینه برای مدل Encoder-Decoder non-aligned joint اتخاذشده

۱ سوال اول: مدل های RNN برای وظایف مشترک درک زبان گفتاری



شکل ۸: نمودار تغییرات دقت برای مدل Encoder-Decoder non-aligned joint اتخاذشده

همچنین طبق نمودارها مشخص است که یادگیری به درستی انجام شده است. مقدار تابع هزینه در طول ایپاک‌ها به‌طور نسبی کاهش یافته است و مقدار دقت افزایش یافته است.

همچنین دقت تشخیص نیات روی داده تست، برابر ۰.۹۳۸۶ است. و مقادیر F1-Score و Classification

Report در قسمت زیر نمایش داده شده است:

```
Test Intent Accuracy: 0.9386
Test Slot F1 Score: 0.5082
Slot Classification Report:
```

	precision	recall	f1-score	support
EOS>	0.00	0.00	0.00	0
aircraft_code	0.00	0.00	0.00	7
airline_code	1.00	0.05	0.09	22
airline_name	0.03	0.02	0.02	91
airport_code	0.00	0.00	0.00	4
airport_name	0.00	0.00	0.00	8
arrive_date.date_relative	0.00	0.00	0.00	1
arrive_date.day_name	1.00	0.10	0.18	10
arrive_date.day_number	0.86	0.86	0.86	7
arrive_date.month_name	0.00	0.00	0.00	7
arrive_time.end_time	1.00	1.00	1.00	3
arrive_time.period_mod	0.00	0.00	0.00	1
arrive_time.period_of_day	0.00	0.00	0.00	8
arrive_time.start_time	0.00	0.00	0.00	3
arrive_time.time	0.33	0.41	0.37	17
arrive_time.time_relative	1.00	0.17	0.29	18
city_name	1.00	0.13	0.24	30
class_type	0.00	0.00	0.00	26
connect	0.00	0.00	0.00	5
cost_relative	0.80	0.11	0.19	38
...				
micro avg	0.57	0.46	0.51	1970
macro avg	0.21	0.13	0.14	1970
weighted avg	0.53	0.46	0.46	1970

شکل ۹: مقادیر F1-Score و Classification Report برای تشخیص اسلات برای مدل Encoder-Decoder non-aligned joint اتخاذشده

دقت شود که برای مدل Encoder-Decoder non-aligned joint، به دلیل عملکرد ضعیف تر نسبت به سایر مدل ها، ترجیح دادیم که مدل را در ۲۰ اپیاک بسنجیم تا به متریک های ذکر شده در صورت سوال برسیم. البته دقت شود که برای ۱۵ اپیاک نیز، در بعضی ران ها میرسیدیم و در بعضی ران ها خیر. اما در ۲۰ اپیاک در قریب به اتفاق موارد به متریک های ذکر شده میرسیدیم، بنابراین مبنا را بر این تعداد اپیاک گذاشتیم و نتایج این بخش نیز با در نظر گرفتن این مورد آورده شده اند.

استفاده از <BOS> و <EOS> در مدل Encoder-Decoder non-aligned joint : در مدل Encoder-Decoder non-aligned joint، برچسب های slots مانند یک جمله در نظر گرفته میشوند که باید توسط مدل تولید شوند. برای اینکه مدل بتواند شروع و پایان این جمله را تشخیص دهد، از توکن های <BOS> و <EOS> استفاده میشود. توکن <BOS> به دیکودر نشان میدهد که فرآیند تولید برچسب ها از کجا آغاز شود و توکن <EOS> مشخص میکند که تولید خروجی در چه زمانی باید متوقف شود. بدون استفاده از این توکن ها، مدل قادر به تشخیص طول مناسب خروجی نخواهد بود و پیش بینی برچسب ها ممکن است ناقص یا نادرست انجام شود.

تفاوت مدل joint non-aligned Encoder-Decoder با joint BiLSTM : در مدل BiLSTM joint، شبکه به صورت مستقیم و همزمان برچسب slot هر توکن و intent کل جمله را پیش بینی میکند. در این ساختار، خروجی برچسب ها به صورت موازی تولید میشوند و وابستگی صریح بین برچسب های متوالی مدل نمیشود. در مقابل، مدل Encoder-Decoder non-aligned joint دارای یک دیکودر است که برچسب های slot را به صورت توکن به توکن تولید میکند. در این حالت، هر برچسب خروجی به برچسب های قبلی وابسته است و مدل میتواند وابستگی های ترتیبی و بلندمدت بین برچسب ها را بهتر یاد بگیرد. مزیت اصلی وجود دیکودر، توانایی مدل در یادگیری ساختار توالی برچسب ها و مدیریت طول های متغیر خروجی است.

علت عملکرد ضعیف تر مدل joint non-aligned Encoder-Decoder : مدل Encoder-Decoder non-aligned joint نسبت به مدل های BiLSTM joint و two separate BiRNN عملکرد ضعیف تری دارد، زیرا فرآیند پیش بینی برچسب های slot در آن به صورت تولید ترتیبی انجام میشود و هر خطای کوچک در مراحل ابتدایی دیکودر میتواند به صورت زنجیره ای به مراحل بعدی منتقل شود. در حالی که در مدل های BiLSTM joint و two separate BiRNN برچسب هر توکن به صورت مستقیم و مستقل از برچسب های قبلی پیش بینی میشود، مدل دیکودر محور وابستگی شدیدی به پیش بینی های قبلی دارد. علاوه بر این، عدم هم ترازای صریح بین

توکن های ورودی و برچسب های خروجی در مدل Encoder-Decoder non-aligned joint باعث میشود یادگیری نگاشت دقیق بین کلمات و برچسب ها دشوارتر شود، در حالی که مدل های مبتنی بر BiLSTM به دلیل هم ترازی طبیعی توکن به توکن، برای مسئله slot filling مناسب تر هستند.

بهبود مدل Encoder-Decoder با استفاده از هم ترازی صریح در مقاله مربوطه برای رفع ضعف مدل های Encoder-Decoder non-aligned در مسئله تشخیص slot ، از هم ترازی صریح بین توکن های ورودی و برچسب های خروجی استفاده شده است. در این روش، فرآیند پیش بینی برچسب ها مشابه ترجمه ماشینی در نظر گرفته میشود، اما برخلاف تولید خودبازگشتی، پیش بینی برچسب ها به صورت هم زمان و متناظر با توکن های ورودی انجام میگیرد.

در این ساختار، به جای فشردن سازی کل جمله در یک نمایش واحد، و سپس بازتولید تدریجی خروجی، وضعیت پنهان هر توکن ورودی به طور مستقیم برای پیش بینی برچسب همان موقعیت استفاده میشود. این هم ترازی صریح که با استفاده از شبکه های مبتنی بر RNN انجام میگیرد، باعث میشود مرز بین اسلات ها حفظ شود و وابستگی مکانی بین توکن و برچسب آن به شکل موثرتری یاد گرفته شود. در نتیجه، دقت تشخیص اسلات ها به طور قابل توجهی بهبود مییابد و مشکل انتشار خطا در دیکودرهای خودبازگشتی کاهش پیدا میکند.

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive

۱-۲ Data Preprocessing

۱-۱-۲

در مرحله اول، مجموعه داده بارگذاری و بررسی شد. ویژگی‌های مربوط به روز و ماه با استفاده از تبدیل‌های سینوسی و کسینوسی به صورت چرخه‌ای در آورده شدند تا مدل بتواند الگوهای دوره‌ای زمان را بهتر شناسایی کند. با بررسی اولیه داده‌ها، مشخص شد چه ویژگی‌هایی در دسترس هستند و محدوده مقادیر آنها چیست. نمودارهای



شکل ۱۰: نمودار زمانی در کل بازه

زمانی برای هر ویژگی در کل بازه داده‌ها رسم شد تا روندها و الگوهای فصلی قابل مشاهده باشند. ویژگی‌های موجود در مجموعه داده عبارتند از: Volume Close, Adj Close, Low, High, Open, Date. مقادیر سال با استفاده از Min-Max Normalization به محدوده [۰, ۱] منتقل شدند. این کار اهمیت دارد زیرا باعث می‌شود ویژگی‌هایی با دامنه عددی بزرگ، بر یادگیری مدل غالب نشوند و همچنین به همگرایی سریع‌تر و پایدارتر شبکه عصبی کمک می‌کند.


۲-۱-۲

با استفاده از کتابخانه statsmodels، نمودارهای Partial و Autocorrelation Function (ACF) برای Autocorrelation Function (PACF) برای ویژگی Close رسم شد. نمودارهای قبل از تقاضاگیری نشان دادند که سری Close دارای وابستگی قوی با مقادیر گذشته است و احتمال وجود روند یا غیرایستایی بودن سری بالا

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive

است. طول پنجره‌ی ورودی مناسب برای مدل می‌تواند بر اساس تعداد لگ‌های معناداری (از صفر فاصله داشته باشند) در نمودار PACF تعیین شود.

سپس سیگنال Close یک بار تفاضل‌گیری شد و دوباره نمودارهای ACF و PACF رسم گردید. بعد از تفاضل‌گیری مشاهده شد که وابستگی بلندمدت از بین رفته و سری نسبتاً ایستا شده است. این تغییر نشان می‌دهد که تفاضل‌گیری برای مدل‌سازی سری زمانی ضروری است و می‌توان از آن برای پیش‌بینی دقیق‌تر استفاده کرد. آزمون Augmented Dickey–Fuller (ADF) نیز اجرا شد و مقدار p-value کمتر از 0.05 بود (نزدیک صفر شد)، که تایید می‌کند سری تفاضل‌گیری شده stationary است و می‌توان از آن در مدل‌های پیش‌بینی استفاده کرد.



شکل ۱۱: نمودارهای ACF و PACF قبل و بعد از تفاضل‌گیری برای سری Close


در این پروژه تمرکز اصلی بر ایستادگی سیگنال به منظور تسهیل یادگیری الگوهای زمانی توسط مدل های یادگیری عمیق است. اگرچه ergodic بودن یک ویژگی نظری مطلوب محسوب می شود، اما در عمل شرط لازم برای آموزش مدل های عمیق نیست. داده های قیمتی خام مانند Open و Close فرآیندهای non-stationary و non-ergodic هستند و نیاز به پیش پردازش دارند.

برای بررسی مفهوم ergodic، ابتدا سری Open و Close را تحلیل کردیم. نمودارهای ACF قبل از تفاضل گیری نشان دادند که وابستگی با مقادیر گذشته حتی بعد از 50 lags هم به صفر نرسیده است. این رفتار نشان می دهد که سری اولیه non-stationary و به احتمال زیاد non-ergodic است، زیرا میانگین و واریانس سری در طول زمان تغییر می کند و نمونه واحد نماینده کل توزیع نیست.

پس از یک بار تفاضل گیری، نمودارهای ACF و PACF نشان دادند که وابستگی بلندمدت از بین رفته و بعد از lag 1 تقریباً به صفر رسیده است. این تغییر نشان می دهد که سری تفاضل گیری شده stationary و تقریباً ergodic شده است، به این معنی که نمونه های سری تفاضل گیری شده نماینده خصوصیات کل توزیع هستند و برای مدل های یادگیری عمیق قابل استفاده می باشند.

بنابراین برای مدل های یادگیری عمیق، توصیه می شود که سیگنال ابتدا stationary یا تفاضل گیری شده استفاده شود تا فرضیات ergodicity برقرار باشد و پیش بینی ها پایدار و قابل اعتماد باشند.

برای آماده سازی داده ها، ابتدا داده های Open و Close با توجه به تعداد lags تقسیم بندی شدند و به دو پنجره ورودی و خروجی اختصاص یافتند. برای پنجره ورودی، سایز پنجره برابر با تعداد تفاضل های لازم برای ایستا کردن سیگنال در نظر گرفته شد و برای پنجره خروجی، طول پنجره با توجه به تعداد lags قابل توجه تعیین شد.




شکل ۱۲: Histogram توزیع داده های ورودی و خروجی

سپس داده ها به سه بخش 70% آموزش، 20% Validation و 10% Test تقسیم شدند. نرمال سازی با Z-score Normalization برای هر سه مجموعه انجام شد تا Data leakage رخ ندهد. در نهایت، هنگام تعریف Loader ها، Shuffling اعمال شد و batch size بر اساس سرعت آموزش بهینه انتخاب شد. همچنین از داده های سال 2024 تا سال 2025 برای مجموعه تست استفاده کردیم.

۲-۲ مدل پایه

۱-۲-۲

شبکه MLP مورد استفاده دارای دو لایه مخفی با تعداد نورون های 128 و 64 و یک Dropout برابر با 0.1 است. Batch size برابر 64 انتخاب شد و مدل برای پیش بینی چهار ویژگی خروجی, Open, Close, High, Low طراحی شده است.




شکل ۱۳: تاریخچه Loss در طول آموزش برای Training و Validation روی داده تست

تحلیل تاریخچه نشان می دهد که Train Loss به مرور کاهش یافته و به مقدار پایین 0.0017 در انتهای آموزش رسیده است. Val Loss نوسانی است ولی به طور متوسط پایین باقی مانده و مقادیر Test Metrics نشان می دهند که مدل عملکرد خوبی دارد:

$$MAPE = 3.46\%, R2 = 0.8341, MAE = 204.2193, RMSE = 220.6531$$

نوسان Val Loss در برخی Epoch ها (مثل Epoch 70 و Epoch 90) مشاهده می شود که می تواند ناشی از پیچیدگی داده یا تغییرات تصادفی در Mini-batch ها باشد، اما با توجه به پایین بودن میانگین Loss و بالابودن R2، آموزش پایدار بوده و مدل قادر است الگوهای زمانی سری را به خوبی یاد بگیرد. این نشان می دهد که شبکه توانسته یادگیری را بدون overfitting شدید انجام دهد و برای پیش بینی آینده سری های مالی مناسب است.

برای بازه 2024 تا 2025 که بخشی از داده تست بوده، پیش‌بینی های مدل MLP با چهار ویژگی Open, Close, High, Low رسم شده‌اند و با قیمت های واقعی مقایسه شده اند.



شکل ۱۴: پیش‌بینی مدل در مقابل قیمت واقعی برای ویژگی های Open, Close, High, Low در بازه ۲۰۲۴-۲۰۲۵

تحلیل نشان می‌دهد که مدل توانسته روند کلی قیمت‌ها را به خوبی دنبال کند و الگوهای زمانی سری را یاد بگیرد. تنها نکته قابل توجه این است که پیش‌بینی ها کمی بالاتر از قیمت واقعی قرار دارند. این موضوع می‌تواند ناشی از نرمال سازی داده‌ها و میانگین گیری در آموزش مدل باشد که باعث می‌شود مدل گرایش به مقادیر کمی بالاتر داشته باشد.

ساختار شبکه همان مدل MLP با دو لایه مخفی (128 و 64 نرون) و Dropout=0.1 بوده و تعداد پارامترهای آن مجموعاً 18884 است .

۳-۲ مدل های Recursive Neural Network

۱-۳-۲ معماری LSTM


۱-۱-۳-۲

۲-۱-۳-۲

در ابتدای معماری، از یک لایه Conv1D با 64 کانال خروجی و اندازه کرنل 7 استفاده شده است. این لایه بر روی بعد زمانی داده ها اعمال میشود و هر فیلتر کانولوشنی یک زیرتوالی از پنجره ورودی را مشاهده میکند. به این ترتیب، الگوهای کوتاه مدت مانند نوسانات محلی قیمت و تغییرات سریع بازار استخراج شده و به صورت feature map در اختیار لایه های بعدی قرار میگیرند.

خروجی لایه کانولوشنی، به لایه LSTM با 64 واحد پنهان داده میشود. این لایه قادر است وابستگی های زمانی بلندمدت را در feature map های استخراج شده مدل سازی کند و اثر نویزهای تصادفی را تا حدی هموار سازد. در این معماری، خروجی گام زمانی آخر LSTM به عنوان نمایش فشرده ای از کل توالی ورودی در نظر گرفته شده است.

در این مدل، به جای استفاده از کل دنباله خروجی LSTM، تنها بردار پنهان مربوط به آخرین گام زمانی به شبکه کاملاً متصل داده شده است. این انتخاب باعث میشود اطلاعات تجمع یافته از کل پنجره زمانی ورودی به صورت فشرده و معنادار در اختیار لایه های انتهایی قرار گیرد و از افزایش غیرضروری تعداد پارامترها جلوگیری شود. در ادامه نمودار loss در طول آموزش را مشاهده می‌کنیم:



شکل ۱۵: مقدار loss روی داده های آموزش و ارزیابی

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive

این نمودار نشان می‌دهد که Train Loss به 0.000115 و Validation Loss به حدود 0.016 رسید. مقدار پایین Val loss آن نشان‌دهنده همگرایی مدل و پایایی آموزش است.

مدل CNN_LSTM با یک لایه Conv1D شامل 64 کانال و یک لایه LSTM با 64 واحد پنهان پیادسازی شد. پس از آن دو لایه Fully Connected با ابعاد 128 و 4 برای پیش‌بینی ویژگی‌های Open, Close, High, Low استفاده شد.

اندازه ورودی 30 و خروجی 4 است. تعداد کل پارامترهای آموزش‌پذیر 45,764 می‌باشد که شامل 3,648 پارامتر کانولوشن، 33,280 پارامتر LSTM و 8,836 پارامتر لایه‌های خطی است. شکل و معماری مدل را می‌توان در شکل ۱۶ مشاهده کرد.

مقادیر متریک روی داده تست عبارتند از: $R^2 = -3.0185$, $MAE = 983.3813$, $RMSE = 1063.8164$, $MAPE = 16.30\%$. توجه شود که مقدار منفی R^2 نشان‌دهنده این است که مدل در مقایسه با مدل ساده میانگین، عملکرد ضعیف‌تری روی داده تست داشته است. این ممکن است به دلیل پیچیدگی داده‌ها و اندازه کوچک مجموعه تست در بازه 2024-2025 باشد.

در ادامه summary مدل را مشاهده می‌کنیم:

Layer (type:depth-idx)	Output Shape	Param #
CNN_LSTM	[64, 4]	--
-Conv1d: 1-1	[64, 64, 26]	3,648
-ReLU: 1-2	[64, 64, 26]	--
-LSTM: 1-3	[64, 26, 64]	33,280
-Linear: 1-4	[64, 128]	8,320
-ReLU: 1-5	[64, 128]	--
-Linear: 1-6	[64, 4]	516
Total params: 45,764		
Trainable params: 45,764		
Non-trainable params: 0		
Total mult-adds (Units.MEGABYTES): 62.01		
Input size (MB): 0.06		
Forward/backward pass size (MB): 1.77		
Params size (MB): 0.18		
Estimated Total Size (MB): 2.02		

شکل ۱۶: خلاصه معماری مدل CNN_LSTM با تعداد پارامترها و شکل لایه‌ها

۲-۳-۲ معماری GRU

۱-۲-۳-۲

برای این مدل CNN+GRU استفاده از hidden feature ها در لایه آخر GRU (h_{last}) معمولاً مناسب تر است. دلیل آن این است که این hidden feature ها اطلاعات تجمعی و وابستگی طولانی مدت سری زمانی را در طول کل پنجره ورودی نگه می‌دارند، در حالی که خروجی مستقیم آخرین گام زمانی صرفاً پیش‌بینی نهایی را نشان می‌دهد و ممکن است بعضی از ویژگی‌های مخفی طولانی مدت را از دست بدهد.

بنابراین توصیه می‌شود برای تحلیل ویژگی‌های پنهان و بهبود نمایش اطلاعات، از hidden features استفاده

شود.

۲-۲-۳-۲

در این بخش مدل CNN+GRU پیاده سازی شده است. ساختار مدل مشابه مدل CNN+LSTM است، با این تفاوت که لایه های LSTM با GRU جایگزین شده اند. معماری مدل به شرح زیر است:


- Conv1D Layer : این لایه وظیفه استخراج ویژگی های محلی و عمق زمانی از سیگنال را بر عهده دارد.

- GRU Layer : این لایه قادر است وابستگی های طولانی مدت در سری زمانی را مدل کند.

- Fully Connected Layers : خروجی آخر GRU در آخرین گام زمانی h_{last} با میانگین ویژگی های Conv1D ($x_{conv_t.mean(dim=1)}$) ترکیب می شود (residual connection) و سپس از طریق لایه های fc1 و fc2 به ابعاد $output_dim=4$ نگاشت داده می شود.

Hyperparameters:

- 0.0005 : Learning rate
- 128 : GRU hidden size
- 5 : GRU layers
- 0.2 : Dropout
- weight_decay=1e-4 with Adam : Optimizer
- MSELoss : Loss function



شکل ۱۷: مقدار خطا روی داده های آموزش و ارزیابی

همانطور که مشخص است مقدار Val loss کاهشی است و یعنی مدل یاد گرفته است و همچنین بهترین نتیجه ای که این مدل برای val loss به ما می دهد عدد 0.016 است.

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive

همچنین متریک ها به صورت زیر است:

R2: 0.7511, MAE: 242.7724, Test RMSE: 264.9567, Val Loss: 0.028808, Train Loss: 0.002870

MAPE: 4.10%

مدل خطای نسبتاً کمی دارد و R2 بالای 0.75 نشان دهنده عملکرد خوب پیش بینی است و از مدل CNN - LSTM

عملکرد خیلی بهتری نشان داده است. summary به صورت زیر است:

Layer (type:depth-idx)	Output Shape	Param #
CNN_GRU	[64, 4]	--
└─Conv1d: 1-1	[64, 64, 26]	3,648
└─ReLU: 1-2	[64, 64, 26]	--
└─GRU: 1-3	[64, 26, 128]	470,784
└─Linear: 1-4	[64, 128]	24,704
└─ReLU: 1-5	[64, 128]	--
└─Dropout: 1-6	[64, 128]	--
└─Linear: 1-7	[64, 4]	516
Total params: 499,652		
Trainable params: 499,652		
Non-trainable params: 0		
Total mult-adds (Units.MEGABYTES): 791.07		
Input size (MB): 0.06		
Forward/backward pass size (MB): 2.62		
Params size (MB): 2.00		
Estimated Total Size (MB): 4.68		

شکل ۱۸: خلاصه معماری CNN - GRU

۴-۲ مقایسه روی داده های تست و مقایسه عملکرد

۱-۴-۲

با توجه به جدول زیر داریم:

جدول ۱: مقایسه عملکرد مدل ها روی داده های تست

مدل	پارامترها	RMSE	MAE	R2	MAPE (%)
MLP	18884	220.65	204.22	0.834	3.46
CNN + LSTM	45764	1063.82	983.38	-3.02	16.30
CNN + GRU	499652	264.96	242.77	0.751	4.10

همانطور که مشخص است بهترین مدل همان مدل Baseline است که هم مقدار R² بالاتری دارد و هم مقدار پارامتر های کمتری برای آموزش دارد و بعد از مدل CNN + Gru که به خوبی train شده است ولی پارامتر های زیادی برای یادگیری دارد و در آخر مدل CNN + LSTM که بدترین عملکرد را از خود نشان داده است.

۲-۴-۲


برای تمامی مدل ها، آموزش روی GPU های T4 در Kaggle انجام شد. زمان تقریبی آموزش برای هر مدل به همراه تعداد FLOPs تقریبی (بر اساس تعداد پارامترهای شبکه) در جدول ?? ارائه شده است.

جدول ۲: زمان آموزش و FLOPs تقریبی برای مدل ها با epochs=100


مدل	تعداد پارامترها	زمان آموزش تقریبی (minutes)	FLOPs تقریبی
MLP	18884	< ۱	3.8e7
CNN + LSTM	45764	1	9.2e7
CNN + GRU	499652	2	9.99e8

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive


پیشبینی قیمت برای سال های ۲۰۲۴ تا ۲۰۲۵ برای هر سه مدل به صورت زیر است:



Predictions MLP (ا)



Predictions CNN + LSTM (ب)




Predictions CNN + GRU (ج)


شکل ۱۹: پیش بینی قیمت ها برای سال های ۲۰۲۴ تا ۲۰۲۵ با سه مدل مختلف

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive


همانطور که مشخص است مدل LSTM خیلی قیمت را پایین تر از حد واقعی تخمین زده است و مدل GRU نسبتاً خوب تخمین زده است و کمی خط نرمی دارد و شبیه خطوط میانگین در نمودار های تحلیلی است و مدل baseline بهترین تخمین را دارد و خیلی خوب همراه نمودار خم می شود. حال پیشبینی سال های آینده استفاده کرد(محور افقی یک سال شیفٹ خورده است)



Predictions MLP (ا)



Predictions CNN + LSTM (ب)



Predictions CNN + GRU (ج)

شکل ۲۰: پیش بینی قیمت ها برای سال های ۲۰۲۵ تا ۲۰۲۶ با سه مدل مختلف

۲ سوال دوم : پیشبینی قیمت سهام با استفاده از معماری های Recursive

همانطور که مشخص است مدل برای پیشبینی سال ۲۰۲۵ تا ۲۰۲۶ ناتوان است بدلیل اینکه این مدل ها صرفا برای پیشبینی روز بعد طراحی شده اند که با خطا همراه هستند و اگر این خطا را به صورت تجمعی در یک سال حساب کنیم مدل بسیار پیشبینی بدی ارائه میکند (به اشتباه سال ۲۰۲۶ تا ۲۰۲۷ رسم نشده است ولی در نمودار mlp همین نمایی ادامه پیدا میکند و در نمودار LSTM نزدیک محور افقی حرکت می کند و در نمودار GRU با همین شیب ملایم ادامه می دهد)