



به نام خدا
دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر



درس شبکه‌های عصبی و یادگیری عمیق

پاسخ تمرین شماره شش

دانشجویان:

فائزه واحدی ۸۱۰۶۰۳۱۶۶

علی رجب زاده ۸۱۰۱۰۴۱۳۷

۵	سوال ۱. بهبود عملکرد شبکه‌های VAE با افزایش ظرفیت توزیع پیشین
۵	۱-۱. سوالات تئوری
۵	۱-۱-۱. تابع هزینه مدل VAE
۶	۱-۱-۲. تابع هزینه مدل جدید
۷	۱-۱-۲. نوع بهبود حاصل از تابع هزینه
۸	۱-۲. آشنایی با مجموعه داده
۹	۱-۳. پیاده سازی در ابعاد نهان پایین
۹	۱-۴. بررسی توزیع ابعاد نهان
۱۱	۱-۵. پیاده سازی در ابعاد نهان بالا
۱۳	۱-۶. بررسی posterior collapse
۱۴	۱-۷. پیمایش فضای پنهان
۱۵	۱-۸. نمایش شبه ورودی ها
۱۶	۱-۹. محاسبه log likelihood

شکل ها

-
- ۸ شکل ۱. تعدادی از نمونه داده DYNAMIC MNIST
- ۹ شکل ۲. تفاوت بین MNIST معمولی و DYNAMIC
- شکل ۳. نمودار سمت چپ مربوط به مقدار کلی تابع هزینه، نمودار وسط مربوط به ترم بازسازی و نمودار سمت راست مربوط به ترم KL می باشد
- ۹ شکل ۴. فضای نهان برای مدل استاندارد و VAMPPRIOR
- ۱۰ شکل ۵. توزیع پیشین و پسین مدل استاندارد
- ۱۰ شکل ۶. توزیع پیشین و پسین مدل VAMPPRIOR
- ۱۱ شکل ۷. نمودارهای تابع هزینه و ترم های آن برای مدل استاندارد و VAMPPRIOR
- ۱۱ شکل ۸. نمودارهای تابع هزینه برای مدل ها با ابعاد پایین و بالا
- ۱۲ شکل ۹. نمونه های تولید شده توسط دو مدل با ابعاد نهان بالا
- ۱۲ شکل ۱۰. میزان فعالیت ابعاد فضای پنهان برای مدل استاندارد و VAMPPRIOR
- ۱۴ شکل ۱۱. پیمایش برای دو مدل استاندارد و VAMPPRIOR
- ۱۵ شکل ۱۲. تعدادی شبه ورودی عبور داده شده از دیکودر (شکل پایینی عبور داده شده از سیگموید)

NO TABLE OF FIGURES ENTRIES FOUND.

سوال ۱. بهبود عملکرد شبکه‌های VAE با افزایش ظرفیت توزیع پیشین

۱-۱. سوالات تئوری

۱-۱-۱. تابع هزینه مدل VAE

تابع هزینه variational autoencoder یک تابع درست‌نمایی لگاریتمی منفی با یک تنظیم‌کننده است. در واقع هدف این مدل بیشینه کردن log likelihood است که به طور مستقیم قابل محاسبه نیست بنابراین از evidence lower bound (ELBO) استفاده می‌شود که بدترین حالت ممکن برای تخمین log-likelihood یک توزیع مشخص است و احتمال واقعی ممکن است بیشتر از مقدار کران پایین شواهد (ELBO) باشد. به عبارت دیگر، تابع هزینه استاندارد در یک مدل اتوانکودر متغیر (VAE)، بیشینه‌سازی حد پایین شواهد (Evidence Lower Bound) یا به اختصار (ELBO) است. این تابع از نظر ریاضی به صورت زیر تعریف می‌شود:

$$l_i(\theta, \phi) = -\mathbb{E}_{z \sim q_\theta(z|x_i)}[\log p_\phi(x_i | z)] + \text{KL}(q_\theta(z | x_i) || p(z))$$

این تابع هزینه از دو بخش اصلی تشکیل شده است که تعادلی را میان دقت بازسازی و ساختار فضای پنهان برقرار می‌کند:

- ترم بازسازی (Reconstruction Term): عبارت اول، میانگین لگاریتم احتمال بازسازی داده‌ها را محاسبه می‌کند. این ترم شبکه را تشویق می‌کند تا کدهایی (Latent Codes) تولید کند که به اندازه کافی غنی باشند تا رمزگشا (Decoder) بتواند تصویر اصلی را با کمترین خطا بازسازی کند.
- ترم تنظیم‌کننده (Regularization Term): عبارت دوم، واگرایی کولبک-لایبلر (KL Divergence) بین توزیع پسین تقریبی $q_\phi(z|x)$ و توزیع پیشین $p(z)$ است.

در واقع واگرایی کولبک-لایبلر (KL Divergence) معیاری برای مقایسه دو توزیع احتمالی است. به حداقل رساندن KL divergence بین توزیع یادگرفته‌شده برای متغیرهای نهان و یک توزیع گاوسی ساده (Gaussian Distribution) با مقادیر استاندارد، باعث می‌شود کدگذاری یادگرفته‌شده از متغیرهای نهانی به شکل توزیع نرمال درآید. این کار اجازه می‌دهد که هر نقطه‌ای در فضای نهانی به شکلی پیوسته و روان به محتوای جدید تبدیل شود و به همین دلیل تولید نمونه‌های جدید ممکن گردد.

نقش فاصله KL در آموزش:

- جلوگیری از بیش‌برازش (Overfitting): بدون این ترم، انکودر ممکن است برای هر داده یک نقطه بسیار دقیق و منزوی در فضای پنهان در نظر بگیرد (شبیه به حفظ کردن داده‌ها). ترم KL با "پخش کردن" این نقاط، از تمرکز بیش از حد جلوگیری می‌کند.
- سازماندهی فضای پنهان: این ترم فضای پنهان را وادار می‌کند تا از یک توزیع مشخص (معمولاً Gaussian استاندارد) پیروی کند. این ویژگی باعث می‌شود که فضای پنهان پیوسته باشد و بتوان از آن برای نمونه‌برداری (Sampling) یا درونیابی (Interpolation) استفاده کرد.

به طور کلی، این معیار می‌سنجد که توزیع پنهان آموخته شده $q_{\phi}(z|x)$ چقدر از توزیع پیشین مطلوب $p(z)$ فاصله دارد. ما می‌خواهیم خروجی‌های کدگذار (همان μ و σ) نزدیک به توزیع پیشین باقی بمانند تا فضای پنهان هموار (Smooth) باشد و نمونه‌برداری از آن، خروجی‌های واقع‌گرایانه ایجاد کند.

۱-۱-۲. تابع هزینه مدل جدید

در VAE استاندارد، توزیع پیشین معمولاً توزیع استاندارد است و یاد گرفته نمی‌شود. در مقاله ارائه شده، نویسندگان پیشنهاد می‌دهند که توزیع پیشین ساده با یک ساختار منعطف‌تر به نام VampPrior (مخفف Variational Mixture of Posteriors) جایگزین شود. در این مقاله ELBO طوری بازنویسی می‌شود که دو ترم تنظیم‌کننده داشته باشد:

$$\begin{aligned}\mathcal{L}(\phi, \theta, \lambda) = & \mathbb{E}_{\mathbf{x} \sim q(\mathbf{x})} [\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\ln p_{\theta}(\mathbf{x}|\mathbf{z})]] + \\ & + \mathbb{E}_{\mathbf{x} \sim q(\mathbf{x})} [\mathbb{H}[q_{\phi}(\mathbf{z}|\mathbf{x})]] + \\ & - \mathbb{E}_{\mathbf{z} \sim q(\mathbf{z})} [-\ln p_{\lambda}(\mathbf{z})]\end{aligned}$$

به این صورت که ترم اول، مربوط به بازسازی و ترم دوم امید ریاضی انتروپی پسین می‌باشد. ترم آخر cross-entropy بین توزیع پسین تجمیع شده (aggregated posterior) و توزیع پیشین است. به زبان ساده ترم دوم انکودر را تشویق می‌کند که انتروپی بالا (واریانس بالا) برای هر دیتا داشته باشد. ترم آخر تلاش می‌کند تا توزیع پسین تجمیع شده و پیشین نزدیک به هم باشند.

اگر بخواهیم ترم آخر بیشینه باشد، توزیع پیشین به صورت میانگین توزیع تجمیع شده پسین باید انتخاب شود. اما این انتخاب دو مشکل دارد: از نظر محاسباتی بسیار گران است (به‌خصوص برای دیتاست‌های بزرگ) و همچنین می‌تواند منجر به overfitting شود چون prior کاملاً به داده‌های آموزش وابسته می‌شود. بنابراین در vamprior به جای جمع روی همه داده‌های واقعی، از تعداد محدودی ورودی مجازی استفاده می‌شود و prior را به صورت «میانگین posteriorها روی این pseudo-inputs» تعریف می‌گردد. در واقع در این مدل، توزیع پیشین دیگر یک توزیع ثابت نیست، بلکه ترکیبی از توزیع‌های پسین است که روی مجموعه‌ای از شبه‌ورودی‌ها (Pseudo-inputs) اعمال شده است:

$$p_{\lambda}(\mathbf{z}) = \frac{1}{K} \sum_{k=1}^K q_{\phi}(\mathbf{z}|\mathbf{u}_k)$$

شبه‌ورودی‌ها پارامترهای قابل یادگیری هستند که ابعادی مشابه داده‌های ورودی دارند اما داده واقعی نیستند. نکته قابل توجه کوپلینگ (Coupling) توزیع پیشین با انکودر است. در این حالت، توزیع پیشین مستقیماً به پارامترهای انکودر وابسته است.

چگونگی افزایش قدرت مدل:

- توزیع چندمدی (Multimodality): توزیع‌های گوسی استاندارد تک‌مدی هستند، در حالی که داده‌های پیچیده (مانند ارقام مختلف دستی) ذاتاً چندمدی هستند. VampPrior با ترکیب چندین مولفه، اجازه می‌دهد فضای

پنهان چندین "خوشه" یا مرکز داشته باشد. در واقع، چون prior می‌تواند چند قله و ساختار غیرگوسی داشته باشد، مدل مجبور نیست همه posteriorها را به یک توزیع نرمال کروی فشرده کند؛ این موضوع از over-regularization جلوگیری می‌کند و latent space منعطف تری را به همراه دارد.

- کاهش خطای تقریب: از نظر تئوری، بهترین توزیع پیشین، میانگین توزیع‌های پسین روی کل داده‌های آموزش است. VampPrior این توزیع بهینه را با استفاده از تعداد محدودی شبه‌ورودی تقریب می‌زند که باعث می‌شود فاصله KL در زمان آموزش واقعی‌تر و دقیق‌تر محاسبه شود.
- کاهش inactive units: در VAE استاندارد، بسیاری از ابعاد نهان عملاً غیر فعال می‌شوند و اطلاعاتی حمل نمی‌کنند؛ تحلیل مقاله نشان می‌دهد که با VampPrior، فشار KL روی ابعاد مختلف متعادل‌تر است و استفاده از ابعاد افزایش می‌یابد.
- جلوگیری از فروپاشی پسین (Posterior Collapse): با ارائه یک توزیع پیشین غنی‌تر، مدل دیگر مجبور نیست ابعاد پنهان را برای تطبیق با یک گوسی ساده غیرفعال کند.

۱-۲. نوع بهبود حاصل از تابع هزینه

وقتی کیفیت خروجی از حد انتظار پایین تر است، چند دسته راه حل ممکن وجود دارد:

- افزایش ظرفیت شبکه (بزرگ‌تر کردن encoder/decoder، افزودن لایه‌های کانولوشنی، استفاده از معماری‌های پیچیده‌تر و ...)
- تغییر prior و تابع هزینه (استفاده از توابع هزینه پیچیده تر یا توزیع‌های پیشین مختلف و ترکیبی)
- تغییر رویه آموزش (تغییر وزن KL، روش‌های ضد فروپاشی پسین، روش‌های ضد over regularization و overfitting)
- ...

اگر شبکه ساده‌ترین ساختارها را هم نمی‌تواند بازسازی کند و underfit می‌شود، با افزایش ظرفیت شبکه می‌توان به نتایج بهتری دست یافت. اما اگر شبکه توان بازسازی را دارد اما عملکرد آن ضعیف است، نمونه‌گیری از توزیع پیشین بد است، فروپاشی پسین رخ می‌دهد و یا latent space نامنظمی دارد که معنی دار نیست، تقویت خود prior و تابع هزینه (مثلاً با VampPrior) راه‌حل منطقی‌تر است، چون این مشکلات از regularization نامناسب و prior بیش از حد ساده ناشی می‌شوند، نه کمبود ظرفیت خام شبکه. در واقع، در بسیاری از موارد، مشکل VAEها کمبود تعداد پارامترهای شبکه (Capacity) نیست، بلکه محدودیت ساختاری ناشی از تحمیل یک توزیع گوسی ساده به داده‌های پیچیده است. وقتی توزیع پیشین بیش از حد ساده باشد، ترم KL به عنوان یک مانع عمل کرده و اجازه نمی‌دهد شبکه از تمام ظرفیت خود برای یادگیری جزئیات استفاده کند (مشکل Over-regularization). به عبارت دیگر، مدل برای کاهش KL تمایل دارد posterior را به سمت یک نرمال ساده و کم‌اطلاعات فشار بدهد؛ نتیجه این می‌شود که بعضی ابعاد نهان غیر فعال می‌شوند (posterior collapse جزئی)، ساختارهای چندمودی یا پیچیده داده در فضای نهان خوب ظاهر نمی‌شوند و کیفیت نمونه‌گیری از prior (که برای تولید ضروری است) ضعیف می‌ماند. در نتیجه در این موارد قبل از بزرگ‌کردن بی‌رویه شبکه، باید طراحی بهتر prior انجام گیرد و ترم‌های منظم‌کننده در تابع هزینه استفاده شود، چون این کار از نظر آماری اصولی‌تر و از نظر محاسباتی پایدارتر است.

۱-۲. آشنایی با مجموعه داده

مجموعه داده Dynamic MNIST نسخه‌ای از MNIST است که برای آموزش و ارزیابی مدل‌های مولد به‌ویژه VAE طراحی شده و در آن، تصاویر به‌صورت پویا و تصادفی دودویی‌سازی (dynamic binarization) می‌شوند. در واقع مجموعه داده Dynamic MNIST نسخه‌ای از MNIST است که در آن مقادیر شدت روشنایی پیکسل‌ها (Grayscale) به عنوان احتمال در نظر گرفته می‌شوند. در MNIST استاندارد، هر پیکسل عددی بین ۰ تا ۲۵۵ است. برای تولید نسخه پویا (Dynamic)، ابتدا مقادیر بین ۰ و ۱ نرمال‌سازی می‌شوند. سپس هر پیکسل به صورت یک متغیر تصادفی برنولی نمونه‌برداری می‌شود. یعنی اگر شدت روشنایی پیکسلی 0.8 باشد، آن پیکسل با احتمال ۸۰٪ برابر با «یک» (سفید) و با احتمال ۲۰٪ برابر با «صفر» (سیاه) قرار داده می‌شود. بنابراین برخلاف MNIST باینری ثابت، هیچ «نسخه ثابت» از تصویر وجود ندارد و هر بار که همان نمونه به مدل داده می‌شود، یک ماسک دودویی متفاوت (ولی سازگار با شدت روشنایی اصلی) ایجاد می‌شود.

در تنظیمات کلاسیک مدل‌های مولد، برای استفاده از MNIST لازم است آن را به نسخه‌ای باینری تبدیل کرد (fixed binarization یا binarized MNIST)، اما اگر این دودویی‌سازی یک‌بار و برای همیشه انجام شود، مدل می‌تواند به همان الگوی ثابت overfit کند و حساسیتش به عدم قطعیت اصلی داده کاهش یابد. Dynamic MNIST دقیقاً برای رفع این مشکل معرفی شده است: در هر iteration، تصویر خاکستری به‌طور تصادفی دودویی می‌شود، بنابراین مدل مولد باید توزیعی را یاد بگیرد که نوسان احتمالات را نیز پوشش دهد، نه فقط یک ماسک قطعی.

استفاده از Dynamic MNIST در آموزش VAE به دلایل زیر برتری دارد:

هماهنگی با تابع احتمال (Likelihood): از آنجا که خروجی لایه آخر دیکودر در VAE‌های معمول برای MNIST، توزیع برنولی است، منطقی است که داده‌های ورودی نیز باینری باشند تا با فرض ریاضی مدل همخوانی داشته باشند.

افزایش قدرت تعمیم: این روش نوعی داده‌افزایی (Augmentation) محسوب می‌شود. به جای دیدن یک تصویر ثابت، مدل با بی‌نهایت نسخه باینری شده از یک تصویر روبروست که باعث می‌شود مدل به جای حفظ کردن پیکسل‌ها، ساختار کلی رقم را یاد بگیرد.

جلوگیری از بیش‌برازش (Overfitting): با تغییر مداوم پیکسل‌ها در هر گام آموزش، احتمال اینکه شبکه عصبی روی نویزهای خاص یا جزئیات بی‌اهمیت تصاویر ثابت قفل شود (Overfit کند)، به شدت کاهش می‌یابد.

فضای نهان منظم‌تر: به دلیل تفاوت ماسک‌ها در هر گذر، مدل مجبور می‌شود توزیع را یاد بگیرد، نه فقط بازسازی یک تصویر مشخص که این باعث بهبود کیفیت ELBO، کاهش overfitting و به دست آمدن فضای نهان منظم‌تر و قابل تعمیم‌تر می‌شود.


در شکل زیر نمونه‌هایی از مجموعه داده Dynamic MNIST مشاهده می‌شود.

Sample of Dynamic MNIST



شکل ۱. تعدادی از نمونه داده Dynamic MNIST


همچنین تصویر زیر تفاوت بین Dynamic MNIST و MNIST معمولی را نشان می دهد.



شکل ۲. تفاوت بین MNIST معمولی و Dynamic

۱-۳. پیاده سازی در ابعاد نهان پایین

نمودارهای مربوط به توابع هزینه در شکل زیر مشاهده می شوند.




شکل ۳. نمودار سمت چپ مربوط به مقدار کلی تابع هزینه، نمودار وسط مربوط به ترم بازسازی و نمودار سمت راست مربوط به ترم KL می باشد

از نمودارها ملاحظه می شود که با وجود اختلاف کم بین منحنی های این دو مدل، تابع هزینه کلی مدل VampPrior با شیب بیشتری نسبت به مدل استاندارد کاهش می یابد. بنابراین در ایپاک های بیشتر میزان loss کمتری خواهد داشت.


۱-۴. بررسی توزیع ابعاد نهان

نمودارهای پراکندگی در شکل زیر ملاحظه می شوند.




شکل ۴. فضای نهان برای مدل استاندارد و VampPrior

مشاهده می شود که در مدل استاندارد با وجود جداپذیری داده های یک سری از اعداد، مانند ۰ و ۱، بسیاری دیگر از داده ها همپوشانی دارند. مثلاً کلاس ۷ به طور کامل بر ۹ منطبق است و جدا پذیر نیستند. اما در مدل VampPrior خوشه ها از یکدیگر جداپذیری بیشتری دارند که با افزایش تعداد اپیک این جداپذیری افزایش می یابد. نمودارهای توزیع پیشین و پسین در فضای نهان برای هر دو مدل در شکل های زیر دیده می شوند.



شکل ۵. توزیع پیشین و پسین مدل استاندارد




شکل ۶. توزیع پیشین و پسین مدل VampPrior

همانطور که پیش تر بررسی شد، توزیع پیشین مدل استاندارد توزیع نرمال است و مدل تلاش میکند تا توزیع پسین را به شکل نرمال در آورد. مشاهده می شود که مدل به طور کامل موفق نبوده است. اما در VampPrior، چون توزیع پیشین خود را از روی شبه‌ورودی‌ها یاد می‌گیرد، دیگر نرمال نیست و به جای یک دایره ساده، به شکل مجموعه‌ای از توده‌ها در می‌آید که دقیقاً داده‌ها را پوشش می‌دهند. این تطبیق باعث کاهش مقدار KL Divergence و در نتیجه بهبود کیفیت بازسازی تصاویر می‌شود. در واقع، در VampPrior، چون prior خودش از posteriorهای pseudo-inputs ساخته شده، شکل prior و aggregated posterior به هم نزدیک‌تر است، توزیع چندمودی و منطبق با ساختار داده شکل می‌گیرد، و این اختلاف در شکل ابر نقاط در نمودارها دیده می‌شود.


۱-۵. پیاده سازی در ابعاد نهان بالا

در شکل زیر نمودار مربوط به آموزش برای دو مدل با ابعاد ۴۰ دیده می شود.



شکل ۷. نمودارهای تابع هزینه و ترم های آن برای مدل استاندارد و VampPrior


در شکل های زیر نمودارهای تابع هزینه در هر مدل با مقایسه با ابعاد پایین مشاهده می شود.



شکل ۸. نمودارهای تابع هزینه برای مدل‌ها با ابعاد پایین و بالا

در هر دو مدل loss در $\text{dim}=40$ به شدت کمتر از ابعاد پایین بوده است. این نشان می‌دهد که Bottleneck در ۲ بعد مانع از یادگیری جزئیات می‌شود، در حالی که ۴۰ بعد اجازه می‌دهد ویژگی‌های ظریف‌تری از اعداد MNIST (مثل انحناهای لبه‌ها) بازسازی شوند. همچنین ملاحظه می‌شود که گاهی اوقات مدل VampPrior، شیب بیشتری داشته و با هر ایپاک به خوبی کاهش می‌یابد. این در حالی است که با حفظ KL بالا مدل دچار collapse نمی‌شود.

در شکل زیر نمونه‌های تولید شده توسط این مدل‌ها دیده می‌شود.



شکل ۹. نمونه‌های تولید شده توسط دو مدل با ابعاد نهان بالا

ملاحظه می شود که با وجود کیفیت تولیدی مناسب هر دو مدل، مدل VampPrior بسیار بهتر عمل کرده و نمونه های تولیدی آن بسیار عالی و به اعداد واقعی نزدیک است. این در حالی است که بعضی از نمونه های مدل استاندارد شبیه به عدد خاصی نیستند. در واقع انگار ترکیب دو رقم می باشند که نشان دهنده جدا ناپذیری مجموعه دادگان در فضای latent آن است.

۱-۶. بررسی posterior collapse

فروپاشی پسین یکی از حالات شکست رایج در مدل های VAE است، به ویژه زمانی که از رمزگشاهای قدرتمند یا ابعاد نهان بالا استفاده می شود. این پدیده زمانی رخ می دهد که توزیع پسین تقریبی $q(z|x)$ به سمت توزیع پیشین $p(z)$ "فروپاشی" می کند و برای برخی از ابعاد فضای پنهان، توزیع پسین به توزیع پیشین نزدیک می شود. از نظر ریاضی، این یعنی:


$$KL(q_\phi(z|x) || p(z)) \rightarrow 0$$

در این حالت، متغیرهای نهان z مستقل از ورودی x می شوند، رمزگذار اطلاعات ورودی را نادیده می گیرد و رمزگشا عملاً فضای نهان را نادیده گرفته و صرفاً میانگین داده ها را تولید می کند (خروجی های تار و یکنواخت). به عبارت دیگر، در VAE ایده آل، هر بعد از z باید اطلاعات معناداری درباره x حمل کند، یعنی $q(z|x)$ با $p(z) = N(0, I)$ متفاوت و به داده وابسته باشد. در posterior collapse، شبکه decoder آن قدر پرقدرت است که می تواند x را تقریباً فقط از noise داخلی خودش بازسازی کند و نیازی به z ندارد. برای کم کردن ترم KL، آموزش به سمتی می رود که $q_\phi(z|x) \approx p(z)$ شود، یعنی $\mu(x) \approx 0$ و $\log \sigma^2(x) \approx 0$ ، و در نتیجه ترم KL روی اکثر داده ها به سمت صفر می رود. در این حالت فضای نهان «می خوابد» و z دیگر حاوی اطلاعات خاص x نیست و aggregated posterior تقریباً همان prior می شود. این پدیده منجر به کاهش کیفیت بازسازی و از دست رفتن ساختار معنادار در فضای نهفته می شود.

دلایل متعددی برای بروز این مشکل وجود دارد که مهم ترین آنها عبارتند از:

- قدرت بیش از حد decoder (در برابر encoder): اگر decoder (مثلاً یک CNN عمیق برای decoder در برابر MLP کوچک برای encoder) توانایی بالایی در مدل سازی داده ها بدون نیاز به z داشته باشد، تمایل پیدا می کند که از متغیر پنهان صرف نظر کند.
- ابعاد بالای فضای پنهان: در صورتی که ابعاد فضای پنهان بیش از حد نیاز باشد، بسیاری از ابعاد ممکن است غیرفعال شوند زیرا مدل نیازی به استفاده از تمام ظرفیت آنها ندارد.
- وزن دهی نامناسب واگرایی KL: در بهینه سازی ELBO، اگر ضریب واگرایی KL بیش از حد بزرگ باشد، مدل مجبور می شود پسین را به پیشین نزدیک کند که می تواند منجر به فروپاشی شود. برعکس، اگر این ضریب خیلی کوچک باشد، ممکن است مدل بیش از حد بر بازسازی تمرکز کند و فضای پنهان نامنظم شود.
- ضعف رمزگذار: اگر رمزگذار نتواند اطلاعات مفید را استخراج کند، پسین به سمت پیشین متمایل می شود.
- استفاده از پیشین ساده: توزیع پیشین نرمال استاندارد ممکن است برای مدل سازی داده های پیچیده کافی نباشد و مدل ترجیح دهد که از آن پیروی کند.

- داده ساده (مثل MNIST)، که اجازه می‌دهد مدل بدون استفاده از z هم به بازسازی خوب برسد. به منظور بررسی فعالیت میزان واریانس میانگین KL برای هر دو مدل سنجیده شده است و نتایج آن در شکل زیر قابل مشاهده می‌باشد.




شکل ۱۰. میزان فعالیت ابعاد فضای پنهان برای مدل استاندارد و VampPrior

مشاهده می‌شود که تعداد ابعاد فعال VampPrior از استاندارد بیشتر بوده و این مدل توانسته posterior collapse را بهبود بخشد.

۷-۱. پیمایش فضای پنهان

پیمایش در فضای پنهان برای دو مدل با ابعاد نهان بالا با ۱۰ قدم در شکل زیر ملاحظه می‌شود.



شکل ۱۱. پیمایش برای دو مدل استاندارد و VampPrior

مشاهده می شود که برای مدل استاندارد، پیمایش دارای پرش ناگهانی است. برای مثال در این شکل به جای تبدیل رقم ۷ به ۲ به صورت روان و smooth، رقم ۷ به صورت ناگهانی تغییر کرده و شبیه به ۳ شده است. در واقع چون توزیع پیشین یک نرمال ساده است، فضای بین خوشه های اعداد ممکن است به خوبی تعریف نشده باشد و فضای نهان نامنظم تر است. اما در مدل VampPrior، تغییرات نسبتاً نرم ترند و این تغییر بدون پرش انجام گرفته است. در واقع گذارها معمولاً بسیار نرم تر و منسجم تر هستند. از آنجایی که توزیع پیشین به عنوان ترکیبی از پسین ها یاد گرفته شده است، شکاف های بین کلاس های مختلف اعداد در فضای نهان به طور موثرتری پر شده اند. این امر منجر به مینیفولدی می شود که در آن حرکت از یک عدد به عدد دیگر، یک تغییر شکل واقعی تر را دنبال می کند.

۸-۱. نمایش شبه ورودی ها

در شکل زیر تعدادی از شبه ورودی های عبور داده شده از دیکودر نشان داده شده است.

First 10 Learned Pseudo-inputs (u_k)



First 10 Learned Pseudo-inputs (u_k)



شکل ۱۲. تعدادی شبه ورودی عبور داده شده از دیکودر (شکل پایینی عبور داده شده از سیگماید)

توزیع VampPrior به عنوان ترکیبی از پسین ها تعریف می شود که بر روی K پارامتر قابل یادگیری به نام شبه ورودی شرطی شده اند. برخلاف VAE استاندارد که در آن توزیع پیشین ثابت و نسبت به داده ها "ناپیدا" است، VampPrior این شبه ورودی ها را در همان فضای داده های ورودی (تصاویر ۲۸ در ۲۸) یاد می گیرد. این ها به عنوان نمونه های اولیه عمل می کنند که ساختار فضای نهان را تعریف می کنند. با نمایش آن ها، می توان "ارقام ایده آل" یا الگوهایی را که مدل

برای درک مجموعه داده MNIST استفاده کرده است، دید. در واقع، pseudo-inputs نمایندگان آماره از توزیع داده‌های واقعی هستند که prior را با posterior واقعی هم‌خوان می‌کنند. نمونه‌ها واقعاً شبیه MNIST هستند چون از posteriorهای واقعی مشتق شده‌اند. pseudo-inputs به prior اجازه می‌دهند یاد بگیرد که z های محتمل چه شکلی باید باشند.

۱-۹. محاسبه log likelihood

در مقاله، معیار اصلی برای مقایسه عملکرد مدل‌ها، لگاریتم درست‌نمایی حاشیه‌ای (Marginal Log-Likelihood) یا همان $\log p(x)$ است. بهینه‌سازی مستقیم $\log p(x)$ در مدل‌های متغیر پنهان (Latent Variable Models) به دلیل عدم امکان محاسبه انتگرال حاشیه‌ای (Intractability) غیرممکن است. یکی دیگر از مشکلات تناقض monte carlo است که بیان می‌کند تخمین log-likelihood با نمونه‌گیری از $q(z|x)$ biased است. رابطه درست‌نمایی به صورت زیر تعریف می‌شود:

$$p(x) = \int p(x|z)p(z)dz$$

در شبکه‌های عصبی عمیق، تابع $p(x|z)$ یک نگاشت غیرخطی پیچیده است. محاسبه این انتگرال مستلزم پیمایش تمام فضای پتانسیل z است که ابعاد بالایی دارد. به همین دلیل، ما به جای بهینه‌سازی مستقیم درست‌نمایی، از کران پایین شواهد (ELBO) استفاده می‌کنیم. طبق قانون تجزیه واریانس، داریم:

$$\log p(x) = \mathcal{L}(x) + D_{KL}(q(z|x)||p(z))$$

چون مقدار KL همواره نامنفی است، ELBO همیشه کوچک‌تر یا مساوی درست‌نمایی واقعی است. ما ELBO را ماکسیم می‌کنیم به این امید که $\log p(x)$ نیز همراه با آن بالا برود.

روش‌های محاسبه لگاریتم درست‌نمایی (Log-Likelihood):

برای ارزیابی دقیق مدل پس از آموزش، باید از روش‌هایی استفاده کرد که تقریب دقیق‌تری نسبت به ELBO ارائه می‌دهند از جمله:

- نمونه‌برداری اهمیت (Importance Sampling - IS): متداول‌ترین روش در VAE‌ها که از توزیع پیشنهادی $q(z|x)$ برای تخمین انتگرال استفاده می‌کند.
- نمونه‌برداری اهمیت آنیل شده (Annealed Importance Sampling - AIS): روشی پیشرفته‌تر برای تخمین ثابت نرمال‌سازی در مدل‌های احتمالاتی است و می‌تواند تخمین دقیق‌تری از لگاریتم درست‌نمایی ارائه دهد، اما پیچیدگی محاسباتی بیشتری دارد. این روش از زنجیره‌ای از توزیع‌های میانی برای انتقال از Prior به Posterior استفاده می‌کند.
- تخمین چگالی پارزن (Parzen Window Estimation): که بیشتر در GAN‌ها استفاده می‌شود و یک توزیع گاوسی پیرامون نمونه‌های تولید شده برازش می‌کند.
- استفاده از کران‌های پایین و بالا: گاهی اوقات به جای یک مقدار نقطه‌ای، یک بازه برای لگاریتم درست‌نمایی گزارش می‌شود. مثلاً ELBO یک کران پایین قطعی است و روش‌هایی برای محاسبه کران بالا نیز وجود دارد.

- روش‌های مبتنی بر معادلات دیفرانسیل معمولی (ODE): در مدل‌های پیوسته‌تر می‌توان از این روش‌ها استفاده کرد.

برای محاسبه نهایی در این گزارش، از روش Importance Sampling با $S=500$ نمونه استفاده شده است. فرمول محاسباتی به شرح زیر است:

$$\log p(x) \approx \log \left(\frac{1}{S} \sum_{s=1}^S \frac{p(x|z_s)p(z_s)}{q(z_s|x)} \right), \quad z_s \sim q(z|x)$$

نتایج برای دو مدل به شرح زیر است:

```
=====
RESULTS (Importance Sampling S=500)
Standard VAE (Latent Dimension = 2): -135.27
VampPrior VAE (Latent Dimension = 2): -134.67
Standard VAE (Latent Dimension = 40): -91.76
VampPrior VAE (Latent Dimension = 40): -88.10
=====
```

مشاهده می‌شود که مدل‌های با ابعاد نهان بالا عملکرد مطلوبی دارند.

(شایان ذکر است به علت قطعی مکرر اینترنت، نوتبوک چندین بار ران گرفته شده و علت تفاوت جزئی و بسیار اندک تصاویر گزارش با تصاویر نوتبوک در همین مسئله می‌باشد)