



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین امتیازی

دانشجویان:

فائزه واحدی ۸۱۰۶۰۳۱۶۶

علی رجب زاده ۸۱۰۱۰۴۱۳۷

فهرست مطالب

۳	فهرست تصاویر
۴	فهرست جداول
۵	۱ تشخیص اصوات شهری با استفاده از مدل Wav2Vec
۵	۱-۱ سوال‌های نظری
۵	۱-۱-۱ عملکرد مدل‌های خودنظارتی
۷	۱-۱-۲ تکنیک‌های افزایش داده صوتی
۸	۲-۱ آموزش و ارزیابی مدل تشخیص صوت
۱۵	۲ Fine Tuning LLM با کمک LoRa در تشخیص احساسات
۱۵	۱-۲ مفاهیم و تعاریف اولیه‌ی Full Fine-Tuning و LoRA Fine-Tuning
۱۷	۲-۲ تعریف مسئله
۱۷	۳-۲ پیاده‌سازی
۱۸	۱-۳-۲ نمونه‌گیری Stratified
۱۸	۲-۳-۲ بارگذاری مدل و tokenizer
۱۸	۳-۳-۲ پیاده‌سازی تابع format_prompt

فهرست تصاویر

۹	نمودار دقت و خطا در طول آموزش برای مدل ۱	۱
۹	نمودار درهم‌ریختگی برای مدل ۱	۲
۹	نمودار سائیز مدل در مقابل دقت برای مدل ۱	۳
۱۰	نمودار دقت و خطا در طول آموزش برای مدل ۲	۴
۱۰	نمودار درهم‌ریختگی برای مدل ۲	۵
۱۰	نمودار سائیز مدل در مقابل دقت برای مدل ۲	۶
۱۱	نمودار دقت و خطا در طول آموزش برای مدل ۳	۷
۱۱	نمودار درهم‌ریختگی برای مدل ۳	۸
۱۱	نمودار سائیز مدل در مقابل دقت برای مدل ۳	۹
۱۲	نمودار دقت و خطا در طول آموزش برای مدل ۴	۱۰
۱۲	نمودار درهم‌ریختگی برای مدل ۴	۱۱
۱۲	نمودار سائیز مدل در مقابل دقت برای مدل ۴	۱۲

فهرست جداول

۱	مقایسه مدل‌ها بر اساس عملکرد و پیچیدگی	۱۳
---	--	----

۱ تشخیص اصوات شهری با استفاده از مدل Wav2Vec

۱-۱ سوال‌های نظری

۱-۱-۱ عملکرد مدل‌های خودنظارتی

الف) مدل Wav2Vec از تابع هزینه‌ای از نوع contrastive loss استفاده می‌کند. هدف این تابع هزینه، یادگیری بازنمایی‌هایی است که تمایز بین نمونه‌های مثبت و منفی را امکان‌پذیر می‌سازد. در هر گام آموزش، مدل یک بازنمایی latent از سیگنال صوتی را تولید می‌کند و سپس باید بتواند بازنمایی‌های صحیح (مثبت) را از مجموعه‌ای از نمونه‌های منفی تشخیص دهد.

نقش Masking در این فرآیند بسیار کلیدی است. بخشی از ویژگی‌های latent به طور تصادفی masked می‌شوند تا مدل مجبور شود اطلاعات گم‌شده را بر اساس زمینه صوتی پیش‌بینی کند. این مکانیزم مشابه cloze task در NLP عمل می‌کند و باعث می‌شود که مدل یاد بگیرد بازنمایی‌های معنادار و جامع از سیگنال صوتی تولید کند.

یکی از نکات مهم این است که مدل بدون داشتن متن می‌تواند بازنمایی‌های معنادار تولید کند، زیرا:

- فرآیند contrastive learning بازنمایی‌ها را به گونه‌ای آموزش می‌دهد که نمونه‌های واقعی (مثبت) از نمونه‌های تصادفی (منفی) متمایز شوند.
- Masking مدل را مجبور می‌کند تا ویژگی‌های مفهومی صدا را یاد بگیرد تا بتواند بخش‌های مخفی‌شده را پیش‌بینی کند.
- به این ترتیب، مدل بازنمایی‌های contextualized تولید می‌کند که اطلاعات مهم صوتی را در خود دارند، حتی بدون دسترسی به متن.

در نتیجه، ترکیب contrastive loss و masking باعث می‌شود مدل Wav2Vec بتواند بازنمایی‌های صوتی با معنای بالا و قابلیت انتقال را یاد بگیرد، بدون نیاز به داده‌های متنی برای آموزش.

ب) مدل Wav2Vec 2.0 و HuBERT هر دو در حوزه بازنمایی صوتی self-supervised فعالیت می‌کنند، اما تفاوت اصلی آن‌ها در رویکرد آموزش نهفته است.

Wav2Vec 2.0 از contrastive learning برای آموزش استفاده می‌کند. در این روش، مدل بازنمایی‌های latent را تولید می‌کند و سپس باید نمونه‌های مثبت (واقعی) را از نمونه‌های منفی (تصادفی) تمایز دهد. Masking بخش‌هایی از بازنمایی latent باعث می‌شود مدل مجبور شود اطلاعات مخفی‌شده را بر اساس زمینه صوتی پیش‌بینی کند. (همان طور که پیشتر گفته شد)

در مقابل، HuBERT از یک رویکرد متفاوت به نام predictive clustering یا masked prediction with pseudo-labels استفاده می‌کند. مراحل اصلی آن عبارتند از:

- ابتدا ویژگی‌های صوتی توسط یک مدل از پیش آموزش‌دیده یا خوشه‌بندی clustering دسته‌بندی می‌شوند تا pseudo-label تولید شود.
 - سپس مدل HuBERT بخش‌هایی از سیگنال صوتی masked شده را پیش‌بینی می‌کند، اما به جای تشخیص نمونه مثبت از منفی، باید pseudo-label درست را بازسازی کند.
- به عبارت دیگر، تفاوت کلیدی این است که:

- Wav2Vec 2.0 بر پایه تمایز بین نمونه‌های مثبت و منفی است (contrastive learning).
- HuBERT بر پیش‌بینی برچسب‌های تولید شده توسط clustering تمرکز دارد (predictive learning).

این تفاوت باعث می‌شود HuBERT بتواند بازنمایی‌های صوتی با تمرکز بیشتر بر ساختار کلاس‌ها و ویژگی‌های مشترک سیگنال صوتی یاد بگیرد، در حالی که Wav2Vec 2.0 بیشتر روی تمایز نمونه‌ها و حفظ اطلاعات زمینه‌ای تمرکز دارد.

پ) مدل‌های استاندارد Mel-Spectrogram + CNN ابتدا سیگنال صوتی را به ویژگی‌های spectrogram تبدیل می‌کنند و سپس با استفاده از CNN این ویژگی‌ها را پردازش می‌کنند. در مقابل، Wav2Vec 2.0 مستقیماً روی raw waveform آموزش می‌بیند.

استفاده از raw waveform چندین مزیت کلیدی دارد:

- حفظ اطلاعات کامل صوتی: تبدیل به Mel-Spectrogram باعث از دست رفتن برخی جزئیات فرکانسی و فاز می‌شود، در حالی که raw waveform تمام اطلاعات سیگنال اولیه را حفظ می‌کند.

- یادگیری ویژگی‌های بهینه به صورت خودکار: مدل Wav2Vec 2.0 می‌تواند ویژگی‌های latent بهینه را بدون وابستگی به ویژگی‌های از پیش تعریف شده (hand-crafted) یاد بگیرد.
 - قابلیت انتقال بهتر: بازنمایی‌های استخراج شده از raw waveform به مدل اجازه می‌دهد که به راحتی به وظایف مختلف مانند ASR یا تشخیص گفتار با گویش‌های مختلف منتقل شوند.
 - انعطاف‌پذیری در پردازش زمان واقعی: مدل‌های مبتنی بر raw waveform می‌توانند مستقیماً با سیگنال‌های طولانی یا جریان صوتی کار کنند، بدون نیاز به پردازش اولیه spectrogram.
- به طور خلاصه، Wav2Vec 2.0 با کار کردن روی raw waveform، بازنمایی‌های صوتی غنی‌تر، معنادارتر و قابل انتقال‌تری نسبت به مدل‌های Mel-Spectrogram + CNN ایجاد می‌کند، در حالی که وابستگی به پیش‌پردازش‌های ثابت کاهش می‌یابد.

۲-۱-۱ تکنیک‌های افزایش داده صوتی

الف) با توجه به ماهیت داده‌های صوتی و نیاز به افزایش مقاومت مدل در برابر نویز و تنوع، چندین تکنیک افزایش داده در دامنه زمانی کاربردی هستند. در ادامه حداقل سه تکنیک رایج معرفی شده است:

- افزودن نویز سفید (Additive White Noise): در این روش، نویز تصادفی به سیگنال raw waveform اضافه می‌شود تا مدل بتواند ویژگی‌های اصلی صدا را حتی در حضور نویز شناسایی کند.
- جابجایی زمانی (Time Shifting): سیگنال به جلو یا عقب در زمان جابجا می‌شود، بدون تغییر فرکانس‌ها. این کار باعث می‌شود مدل نسبت به تغییرات زمانی و شروع متفاوت سیگنال مقاوم شود.
- تغییر سرعت یا طول مدت (Time Stretching / Speed Perturbation): سیگنال با فاکتور کوچکی کشیده یا فشرده می‌شود، که مدل را قادر می‌سازد تا نسبت به تغییرات سرعت صحبت یا طول واژه‌ها مقاوم باشد.

این تکنیک‌ها به مدل اجازه می‌دهند که بازنمایی‌های صوتی قوی‌تر و مقاوم‌تری نسبت به نویز و تغییرات طبیعی در سیگنال‌های صوتی یاد بگیرد.

ب) با وجود پیشرفت مدل‌های self-supervised مانند Wav2Vec 2.0، ویژگی‌های مهندسی شده (hand-engineered features) هنوز برای بسیاری از وظایف صوتی اهمیت دارند. در ادامه سه ویژگی مهم و کاربرد آن‌ها آورده شده است:

• **Pitch (ارتفاع صدا):**

– **وظیفه کاربردی:** تشخیص جنسیت یا گویش (Speaker Gender / Speaker Identification)
– **چرا برای ASR مناسب نیست:** Pitch تنها اطلاعات فرکانسی اصلی صدا را نشان می‌دهد و اطلاعات دقیق محتوا و واج‌ها (phonemes) را ارائه نمی‌کند، بنابراین برای بازشناسی گفتار (ASR) کافی نیست.

• **MFCC (Mel-Frequency Cepstral Coefficients):**

– **وظیفه کاربردی:** تشخیص گفتار (Automatic Speech Recognition)
– **چرا برای تشخیص احساس مناسب نیست:** MFCC بیشتر بر محتوای صوتی تمرکز دارد و تغییرات لحنی و هیجانی (prosody / emotion) را به خوبی نشان نمی‌دهد، بنابراین برای تشخیص حالت هیجانی صدا مناسب نیست.

• **Formants (فرکانس‌های رزونانسی):**


– **وظیفه کاربردی:** تشخیص واج‌ها یا تلفظ (Phoneme / Articulation Recognition)
– **چرا برای تشخیص گوینده مناسب نیست:** Formants بیشتر ویژگی‌های واجی و ساختاری صدا را نشان می‌دهند و اطلاعات منحصر به فرد گوینده (speaker-specific features) مانند تن صدا یا الگوهای گفتاری را به اندازه کافی شامل نمی‌شوند.

به این ترتیب، هر ویژگی مهندسی شده برای یک وظیفه خاص بسیار مناسب است، اما در وظایف دیگر اهمیت یا اثرگذاری کمتری دارد، زیرا اطلاعات مورد نیاز آن وظیفه را به صورت جامع ارائه نمی‌کند.


۲-۱ آموزش و ارزیابی مدل تشخیص صوت

پس از آموزش مدل‌های خواسته‌شده، نتایج زیر بدست آمده است:


مدل ۱:



شکل ۱: نمودار دقت و خطا در طول آموزش برای مدل ۱




شکل ۲: نمودار درهم‌ریختگی برای مدل ۱




شکل ۳: نمودار سایز مدل در مقابل دقت برای مدل ۱


مدل ۲:



شکل ۴: نمودار دقت و خطا در طول آموزش برای مدل ۲




شکل ۵: نمودار درهم‌ریختگی برای مدل ۲




شکل ۶: نمودار سایز مدل در مقابل دقت برای مدل ۲


مدل ۳:



شکل ۷: نمودار دقت و خطا در طول آموزش برای مدل ۳




شکل ۸: نمودار درهم‌ریختگی برای مدل ۳




شکل ۹: نمودار سایز مدل در مقابل دقت برای مدل ۳


مدل ۴:



شکل ۱۰: نمودار دقت و خطا در طول آموزش برای مدل ۴



شکل ۱۱: نمودار درهم‌ریختگی برای مدل ۴



شکل ۱۲: نمودار سایز مدل در مقابل دقت برای مدل ۴

جدول ۱: مقایسه مدل‌ها بر اساس عملکرد و پیچیدگی

Model	Accuracy	(Macro) F ^۱	Error	Parameters Trainable
Basic CNN (Scratch)	0.565	0.515	0.435	24,170
Full Fine-Tuning Wav2Vec2	0.881	0.881	0.119	94,379,402
Frozen Wav2Vec2 (Classifier Only)	0.394	0.369	0.606	7,690
Partial Freeze Wav2Vec2	0.801	0.811	0.199	47,651,722

تحلیل نتایج نشان می‌دهد که مدل CNN پایه با تعداد پارامترهای کم، دقت متوسطی (۵۶,۵٪) دارد و توانایی استخراج ویژگی‌های پیچیده از صداها را محدود است.

مدل Wav2Vec2 با تنظیم دقیق کامل بهترین عملکرد را با دقت ۸۸,۱٪ و Macro F1 برابر با ۰,۸۸۱ دارد. این مدل با تمام پارامترها قابل آموزش، قابلیت یادگیری ویژگی‌های سطح بالا و نمایش دقیق صداها را دارد، اما هزینه محاسباتی بسیار بالایی دارد (زمان هر epoch حدود ۷۲۰ ثانیه).

در مقابل، مدل فریز کامل Wav2Vec2 که تنها لایه طبقه‌بند آن آموزش می‌بیند، با وجود کمترین تعداد پارامتر قابل آموزش، دقت پایینی (۳۹,۴٪) ارائه می‌دهد. این نشان می‌دهد که استفاده از نمایه‌های پیش‌آموزش دیده بدون به‌روزرسانی لایه‌های بالاتر، برای این وظیفه کافی نیست.

مدل فریز جزئی Wav2Vec2 با آزادسازی تنها لایه‌های بالایی و لایه طبقه‌بند، عملکرد مناسبی (۸۰,۱٪) ارائه می‌دهد. این مدل تعادل مناسبی بین دقت و تعداد پارامترهای قابل آموزش ایجاد کرده و نشان می‌دهد که فریز جزئی لایه‌ها یک استراتژی بهینه برای استفاده از مدل‌های پیش‌آموزش دیده در مسائل با منابع محاسباتی محدود است.

نتایج نشان می‌دهد که:

- افزایش تعداد پارامترهای قابل آموزش به طور مستقیم با دقت مدل رابطه مثبت دارد، ولی هزینه محاسباتی را نیز افزایش می‌دهد.
- فریز کامل مدل‌های پیش‌آموزش دیده منجر به کاهش چشمگیر دقت می‌شود.
- فریز جزئی، با آزادسازی بخش‌هایی از شبکه و لایه طبقه‌بند، تعادل مناسبی بین دقت و پیچیدگی محاسباتی ایجاد می‌کند.

در مجموع، بهترین ترکیب برای این وظیفه، استفاده از مدل Wav2Vec2 با فریز جزئی است که دقت بالایی ارائه می‌دهد و نیاز به آموزش تمام پارامترها ندارد.

سوال اول

مدل پایه CNN ساده و با پارامتر کم است، دقت متوسط (۵۶,۵٪) دارد و برای محیط‌های با منابع محدود مناسب است. Full Fine-Tuning Wav2Vec2 بهترین عملکرد (۸۸,۱٪) را دارد و زمانی مناسب است که منابع و زمان کافی برای آموزش وجود داشته باشد. Frozen Wav2Vec2 با آموزش تنها لایه طبقه‌بند، دقت پایینی (۳۹,۴٪) دارد و فقط برای ارزیابی سریع یا منابع بسیار محدود توصیه می‌شود. Partial Freeze Wav2Vec2 تعادل خوبی بین دقت (۸۰,۱٪) و پیچیدگی محاسباتی دارد و زمانی مناسب است که بخواهیم از مدل pretrained بهره ببریم ولی منابع محدود باشد.

سوال دوم

خیر، افزایش تعداد پارامترهای قابل آموزش همیشه باعث بهبود عملکرد مدل نمی‌شود. اگرچه مدل‌های با پارامترهای بیشتر مانند Full Fine-Tuning Wav2Vec2 قادر به یادگیری ویژگی‌های پیچیده‌تر هستند، ولی این افزایش پارامترها به تنهایی تضمینی برای دقت بالاتر نیست. مدل‌هایی با پارامترهای زیاد ممکن است بیش‌برازش (overfitting) داشته باشند و نیاز به منابع محاسباتی و داده‌های بیشتر دارند. همان‌طور که در نتایج مشاهده شد، Partial Freeze Wav2Vec2 با تقریباً نیمی از پارامترها عملکرد نزدیک به مدل کامل داشت و مدل پایه CNN با پارامتر کم نیز توانست دقت متوسطی ارائه دهد. بنابراین، کیفیت ویژگی‌های یادگرفته شده و استراتژی آموزش به اندازه تعداد پارامترها اهمیت دارد.

۲ Fine Tuning LLM با کمک LoRa در تشخیص احساسات

۱-۲ مفاهیم و تعاریف اولیه‌ی LoRA Fine-Tuning و Full Fine-Tuning

در یادگیری عمیق، روش Fine-Tuning کامل به این صورت است که یک مدل از پیش‌آموزش‌دیده انتخاب شده و بخش عمده یا تمام وزن‌های آن بر روی داده‌های دامنه‌ی جدید مجدداً آموزش داده می‌شوند. در مقابل، در روش LoRA Fine-Tuning (مخفف Low-Rank Adaptation) وزن‌های اصلی مدل فریز شده و تنها ماتریس‌های کم‌رتبه‌ی افزودنشده به برخی لایه‌ها آموزش داده می‌شوند.

مزایا و معایب Fine-Tuning کامل

مزایا:

- حداکثر انعطاف‌پذیری: تمامی پارامترهای مدل قابل به‌روزرسانی هستند، بنابراین مدل می‌تواند به‌طور کامل با دامنه‌ی جدید سازگار شود.
- عملکرد بالقوه بالاتر در صورت وجود داده‌ی کافی و منابع محاسباتی مناسب.
- مناسب برای مواردی که فاصله‌ی دامنه‌ی جدید با دامنه‌ی پیش‌آموزش زیاد است.

معایب:

- هزینه‌ی محاسباتی و حافظه‌ای بسیار بالا (نیاز به ذخیره و به‌روزرسانی تمام گرادیان‌ها).
- نیاز به نگهداری یک نسخه‌ی کامل از مدل برای هر وظیفه‌ی جدید.
- خطر بیش‌برازش (Overfitting) در صورت کم بودن داده‌ی دامنه‌ی جدید.

مزایا و معایب LoRA Fine-Tuning

در روش LoRA، اگر وزن یک لایه‌ی خطی را با $W \in \mathbb{R}^{d \times k}$ نشان دهیم، به‌جای به‌روزرسانی مستقیم W ، یک ماتریس افزاینشی به صورت

$$\Delta W = BA$$

در نظر گرفته می‌شود که در آن

$$A \in \mathbb{R}^{r \times k}, \quad B \in \mathbb{R}^{d \times r},$$

و $r \ll \min(d, k)$ است. در این حالت تنها پارامترهای A و B آموزش داده می‌شوند و W ثابت باقی می‌ماند.

مزایا:

- کاهش چشمگیر تعداد پارامترهای قابل آموزش.
- کاهش مصرف حافظه (عدم نیاز به ذخیره‌ی گرادیان برای وزن‌های اصلی).
- امکان نگهداری چندین Adapter کوچک برای وظایف مختلف به جای ذخیره‌ی چند مدل کامل.
- مناسب برای تنظیم مدل‌های بسیار بزرگ (LLMs) با منابع محدود.

معایب:

- محدودیت در ظرفیت بیان تغییرات (به دلیل کم‌رتبه بودن ΔW).
- در صورت تفاوت زیاد دامنه‌ی جدید با دامنه‌ی اولیه، ممکن است عملکرد بهینه حاصل نشود.
- نیاز به انتخاب مناسب رتبه‌ی r که یک ابرپارامتر حساس است.

مثال عددی برای نشان دادن مزیت اصلی LoRa

فرض شود یک مدل زبانی بزرگ با ۷ میلیارد پارامتر (7B parameters) در اختیار است. در روش Fine-Tuning کامل، تمامی این ۷ میلیارد پارامتر باید آموزش داده شوند. اگر هر پارامتر به صورت عدد ممیز شناور ۴ بایتی (FP32) ذخیره شود، تنها برای وزن‌ها حدود

$$7 \times 10^9 \times 4 \approx 28 \text{GB}$$

حافظه نیاز خواهد بود (بدون در نظر گرفتن گرادیان‌ها و پارامترهای بهینه‌ساز که این مقدار را تقریباً ۲ تا ۳ برابر می‌کنند).

اکنون فرض شود در هر لایه‌ی ترنسفورمر، یک ماتریس وزن با ابعاد 4096×4096 وجود دارد. تعداد پارامترهای این ماتریس برابر است با:

$$4096 \times 4096 \approx 16,777,216$$

پارامتر (حدود ۷.۱۶ میلیون).

اگر در روش LoRA رتبه‌ی $r = 8$ انتخاب شود، تعداد پارامترهای افزودشده برابر خواهد بود با:

$$r \times (4096 + 4096) = 8 \times 8192 = 65,536$$

پارامتر.

یعنی به جای آموزش حدود ۷.۱۶ میلیون پارامتر در آن لایه، تنها حدود ۶۵ هزار پارامتر آموزش داده می‌شود؛ یعنی بیش از ۲۵۰ برابر کاهش در تعداد پارامترهای قابل آموزش. در مقیاس کل مدل، این کاهش می‌تواند از میلیاردها پارامتر به چند میلیون پارامتر برسد. این مثال عددی نشان می‌دهد که مزیت اصلی LoRA در کاهش چشمگیر هزینه‌ی حافظه و محاسبات است، در حالی که بخش عمده‌ی دانش مدل پایه حفظ می‌شود. بنابراین، LoRA روشی بسیار کارآمد برای تنظیم مدل‌های زبانی بزرگ در شرایط محدودیت منابع محسوب می‌شود.

۲-۲ تعریف مسئله

این قسمت برای آشنایی با مسئله در فایل سوالات قرار داده شده بود و گزارشی نیاز نداشت.

۳-۲ پیاده‌سازی

چندتا از بخش‌های بعدی کدشان در فایل ژوپیتر آورده شده است. اما هرچقدر سعی کردم نتوانستم به مدل ذکرشده در huggingface دسترسی پیدا کنم. اما کدها را پیاده‌سازی کردم. کدها با فرض دسترسی صحیح، درست کار میکنند.

۱-۳-۲ نمونه‌گیری Stratified

۲-۳-۲ بارگذاری مدل و tokenizer

۳-۳-۲ پیاده‌سازی تابع format_prompt